

Reti Neurali Spiking (SNN)

NECKER

6 Settembre 2026

Contents

1	Introduzione: Il Paradigma Neuromorfico	2
2	Il Neurone Biologico e la Codifica dell'Informazione	2
2.1	Meccanismi di Codifica del Segnale (Spike Coding)	2
2.1.1	1. Codifica in Frequenza (Rate Coding)	2
2.1.2	2. Codifica Temporale (Temporal Coding)	3
2.1.3	3. Codifica di Popolazione (Population Coding)	3
3	Modelli Matematici del Neurone Spiking	5
3.1	Il Modello Leaky Integrate-and-Fire (LIF)	5
3.1.1	Spiegazione Biofisica Della Catena di Trasmissione Sinaptica	5
3.1.2	Derivazione Analitica tramite la Legge di Kirchhoff	8
3.2	Modelli Avanzati e Conduttanza-Dipendenti	12
4	Sinapsi e Modelli di Corrente Sinaptica	12
4.1	Modello Delta-Current:	12
4.2	Modello a Conduttanza (Esponenziale):	12
5	Apprendimento nelle Reti Neuromorfiche	13
5.1	Fondamenti Biologici: Cosa significa fisicamente "imparare"?	13
5.2	1. Apprendimento Non Supervisionato: Plasticità Ebbiana e STDP	14
5.2.1	regola matematica di addestramento:	15
5.3	2. Supervisione tramite Gradienti Surrogati (Surrogate Gradients)	16
5.4	3. Conversione da ANN a SNN	18
6	Le SNN nell'Embodied AI: Vantaggi e Hardware Neuromorfico	19
7	Conclusioni e Frontiere della Ricerca	19

1 Introduzione: Il Paradigma Neuromorfico

Nel dominio dell'Intelligenza Artificiale, mentre l'attenzione computazionale è attualmente dominata dalle architetture basate su Transformer e Large Language Models, esiste un filone di ricerca focalizzato non sulla profondità semantica, ma sull'efficienza energetica, la latenza biologica e il realismo fisiologico: le **Reti Neurali Spiking (SNN)**.

Le SNN rappresentano la "terza generazione" delle reti neurali, succedendo ai perceptron di prima generazione (output binari) e alle ANN di seconda generazione (funzioni di attivazione continue come Sigmoid o ReLU). La distinzione fondamentale risiede nel trattamento del tempo: nelle ANN il tempo è discretizzato per layer e le attivazioni sono frame-based; nelle SNN, il tempo è una variabile continua intrinseca e l'informazione è veicolata dall'istante esatto di emissione di un potenziale d'azione, o **spike**.

Questo cambio di paradigma offre promesse rivoluzionarie per l'Embodied AI, specialmente quando accoppiato a sensori neuromorfici (come le Event Cameras) e hardware dedicato (come i chip Intel Loihi o IBM TrueNorth), promettendo consumi energetici nell'ordine dei milliwatt per task visuo-motori complessi.

2 Il Neurone Biologico e la Codifica dell'Informazione

Per comprendere le SNN, è necessario esaminare un neurone biologico il quale riceve segnali chimici attraverso i dendriti, che alterano il potenziale elettrico della sua membrana citoplasmatica. Se questo potenziale supera una determinata soglia critica, il neurone "spara" un impulso elettrico stereotipato (spike) lungo l'assone, che si propaga alle sinapsi dei neuroni successivi.

2.1 Meccanismi di Codifica del Segnale (Spike Coding)

Nelle reti neurali convenzionali (ANN), l'informazione è rappresentata da valori continui in virgola mobile a 32 bit (es. l'attivazione di un neurone vale $x = 0.85$). Al contrario, in una Spiking Neural Network (SNN), tutti i potenziali d'azione (spike) possiedono ampiezza e durata stereotipate: l'output istantaneo di un neurone è un evento puramente binario $S(t) \in \{0, 1\}$.

Di conseguenza, sorge un problema ingegneristico fondamentale: **come tradurre una grandezza fisica continua $x \in [0, 1]$ in una sequenza temporale discreta di spike?**

In letteratura neuroscientifica e ingegneristica non esiste un'unica risposta; sono stati formalizzati tre paradigmi alternativi (o protocolli di trasmissione), ciascuno basato su presupposti computazionali differenti.

2.1.1 1. Codifica in Frequenza (Rate Coding)

In questo paradigma, l'informazione risiede esclusivamente nel **numero totale di spike** emessi all'interno di una finestra temporale fissa di durata T , indipendentemente dalla loro precisa distribuzione temporale. L'intensità dello stimolo x viene mappata linearmente nella frequenza media di scarica (r):

$$r = \frac{1}{T} \int_0^T S(t) dt \approx \frac{N_{\text{spike}}}{N_{\text{step}}} \propto x$$

$\propto$ indica la proporzionalità diretta tra due grandezze.

Esempio Pratico: Consideriamo un sensore di pressione su un gripper che misura un contatto intenso ($x = 0.80$) oppure un contatto lieve ($x = 0.20$) su un intervallo discretizzato di $T = 10$ passi temporali:

- **Forte pressione ($x = 0.80$):** Il neurone genera 8 spike su 10 intervalli:

$$S(t) = [1, 1, 0, 1, 1, 1, 0, 1, 1, 1] \implies \frac{8}{10} = 0.80$$

- **Lieve pressione ($x = 0.20$):** Il neurone genera solo 2 spike su 10 intervalli:

$$S(t) = [0, 0, 1, 0, 0, 0, 0, 1, 0, 0] \implies \frac{2}{10} = 0.20$$

Compromesso: È il metodo più robusto contro il rumore sensoriale (la perdita di un singolo impulso altera marginalmente la frequenza media) ed è alla base della conversione diretta da ANN a SNN. Tuttavia, è **altamente inefficiente dal punto di vista della latenza e dei consumi**: il neurone ricevente deve attendere l'intero intervallo T per accumulare e stimare la frequenza corretta.

2.1.2 2. Codifica Temporale (Temporal Coding)

A differenza del Rate Coding, qui il tempo esatto di occorrenza del singolo spike trasporta informazione critica. Non si conta la quantità di impulsi, ma si "legge l'orologio" all'istante di arrivo. Esistono due implementazioni primarie:

- **Time-to-First-Spike (TTFS o Latenza):** L'intensità dello stimolo è inversamente proporzionale alla latenza del primo spike rispetto all'inizio della rilevazione ($t = 0$). Uno stimolo intenso porta il potenziale di membrana a soglia molto più rapidamente di uno stimolo debole:

$$t_{\text{spike}} = t_0 - \tau \ln(x)$$

Esempio: Per la pressione forte $x = 0.80$, il neurone emette un singolo spike quasi istantaneamente al passo $t = 1$ ms; per la pressione lieve $x = 0.20$, il neurone impiega tempo per integrare la carica ed emette lo spike al passo $t = 9$ ms. Il neurone post-sinaptico determina il valore misurando l'intervallo trascorso dall'inizio dello stimolo, ottenendo latenza decisionale pressoché istantanea con un singolo spike.

- **Inter-Spike Interval (ISI):** L'informazione è codificata nella distanza temporale relativa $\Delta t = t_{k+1} - t_k$ tra due impulsi consecutivi, dove un intervallo compresso corrisponde a uno stimolo intenso e un intervallo dilatato a uno stimolo debole. A differenza del TTFS, che risolve la lettura con un singolo evento ma richiede un segnale di sincronizzazione globale ($t = 0$), l'ISI necessita di una sequenza continua di almeno due spike per definire l'intervallo, operando però in modo asincrono e autosufficiente senza riferimenti temporali esterni.

Compromesso: Massima efficienza energetica (richiede spesso un solo spike per evento) e reattività millimetrica, ideale per il controllo reattivo ad anello chiuso. Di contro, è estremamente vulnerabile al rumore temporale (*jitter*): un'oscillazione anche minima nel clock hardware distorce il dato trasmesso.

2.1.3 3. Codifica di Popolazione (Population Coding)

Poiché i neuroni biologici individuali sono soggetti a forti componenti stocastiche, il sistema nervoso distribuisce spesso la codifica di una singola variabile continua su un insieme (*pool*) di neuroni cooperanti. Ciascun neurone della popolazione possiede una "curva di sintonizzazione" (*tuning curve*) gaussiana centrata su una specifica porzione del dominio:

$$f_i(x) = \exp\left(-\frac{(x - \mu_i)^2}{2\sigma_i^2}\right)$$

- $f_i(x) \in [0, 1]$: Rappresenta il **livello di attivazione** (o la risposta normalizzata) dell' i -esimo neurone della popolazione a fronte dello stimolo scalare x . Assume valore massimo pari a 1 quando lo stimolo coincide esattamente con la preferenza del neurone, e decade asintoticamente verso 0 man mano che lo stimolo si allontana.
- x : È il **valore continuo dello stimolo** in ingresso (es. la forza di contatto misurata dal sensore o l'angolo di un giunto) che la popolazione neuronale deve codificare.
- μ_i : È il **centro di sintonizzazione** (*tuning center* o media) dell' i -esimo neurone. Definisce il valore specifico dello stimolo a cui il neurone è massimamente sensibile: per $x = \mu_i$, l'esponente si annulla e $f_i(\mu_i) = \exp(0) = 1$. (anche se il risultato del denominatore fa zero, l'esponenziale porta l'output a 1, quindi questo valore rappresenta esattamente la "classe" del neurone)
- $(x - \mu_i)^2$: Rappresenta la **distanza euclidea quadratica** tra lo stimolo corrente x e il valore preferito dal neurone μ_i . Il quadrato garantisce che la risposta decada simmetricamente in entrambe le direzioni (sia per eccesso che per difetto).
- σ_i : È la **larghezza di banda** (*tuning width* o deviazione standard) del campo recettivo. Controlla la selettività del neurone: un valore di σ_i piccolo produce una risposta stretta e altamente specifica, mentre un σ_i grande determina una risposta ampia e diffusa, aumentando la sovrapposizione con i neuroni adiacenti.
- $2\sigma_i^2$: È il **fattore di scala a denominatore** che normalizza la dispersione della campana gaussiana. All'aumentare di questo termine, la pendenza del decadimento si attenua.
- $\exp(-\cdot)$: La funzione esponenziale negativa mappa la distanza normalizzata nell'intervallo $(0, 1]$, trasformando la discrepanza metrica in un profilo a campana (*Radial Basis Function*, RBF) liscio e differenziabile.

una volta calcolati i vari valori $f_i(x) \in [0, 1]$ di attivazione, per ricostruire l'effettivo valore di ingresso iniziale, si usa la formula:

$$\hat{x} = \frac{\sum_i f_i \cdot \mu_i}{\sum_i f_i}$$

Esempio Pratico: fissiamo i parametri dimensionali di una popolazione di tre neuroni (N_1, N_2, N_3) adibiti alla codifica dell'angolo di rotazione del polso $x \in [0^\circ, 180^\circ]$:

- Centri di sintonizzazione: $\mu_1 = 0^\circ, \mu_2 = 90^\circ, \mu_3 = 180^\circ$.
- Larghezza di banda costante: $\sigma_1 = \sigma_2 = \sigma_3 = 30^\circ$.
- Fattore di scala al denominatore: $2\sigma^2 = 2 \cdot (30)^2 = 2 \cdot 900 = 1800$.

Supponiamo che il sensore rilevi un angolo effettivo pari a $x = 120^\circ$. Tracciamo il calcolo passaggio per passaggio per ciascuno dei tre neuroni:

1. **Neurone N_1 (Specializzato a $\mu_1 = 0^\circ$):**

- Distanza quadratica: $(x - \mu_1)^2 = (120 - 0)^2 = 120^2 = 14400$.
- Argomento normalizzato: $\frac{(x - \mu_1)^2}{2\sigma_1^2} = \frac{14400}{1800} = 8.0$.
- Livello di attivazione:

$$f_1(120^\circ) = \exp(-8.0) \approx 0.0003 \approx 0.03\%$$

La notevole discrepanza tra x e μ_1 annulla quasi del tutto la scarica del primo neurone.

2. **Neurone N_2 (Specializzato a $\mu_2 = 90^\circ$):**

- Distanza quadratica: $(x - \mu_2)^2 = (120 - 90)^2 = 30^2 = 900$.
- Argomento normalizzato: $\frac{(x - \mu_2)^2}{2\sigma_2^2} = \frac{900}{1800} = 0.5$.
- Livello di attivazione:

$$f_2(120^\circ) = \exp(-0.5) \approx 0.6065 \approx 60.65\%$$

Lo scostamento è contenuto all'interno di una deviazione standard ($|120 - 90| = \sigma$), determinando un'attivazione robusta e dominante.

3. **Neurone N_3 (Specializzato a $\mu_3 = 180^\circ$):**

- Distanza quadratica: $(x - \mu_3)^2 = (120 - 180)^2 = (-60)^2 = 3600$.
- Argomento normalizzato: $\frac{(x - \mu_3)^2}{2\sigma_3^2} = \frac{3600}{1800} = 2.0$.
- Livello di attivazione:

$$f_3(120^\circ) = \exp(-2.0) \approx 0.1353 \approx 13.53\%$$

La distanza pari a due deviazioni standard riduce significativamente la risposta, lasciando però una componente residua misurabile.

Ricostruzione del Valore tramite Vettore di Popolazione: Il vettore delle risposte normalizzate emesso dallo strato sensoriale è:

$$\mathbf{f}(120^\circ) = [f_1, f_2, f_3]^T \approx [0.0003, 0.6065, 0.1353]^T$$

Il circuito post-sinaptico può quindi ricostruire lo stimolo continuo originario calcolando il centroide ponderato dell'attività della popolazione (*Population Vector Decoding*):

$$\hat{x} = \frac{\sum_{i=1}^3 f_i(x) \cdot \mu_i}{\sum_{i=1}^3 f_i(x)} = \frac{(0.0003 \cdot 0^\circ) + (0.6065 \cdot 90^\circ) + (0.1353 \cdot 180^\circ)}{0.0003 + 0.6065 + 0.1353}$$

$$\hat{x} = \frac{0 + 54.585 + 24.354}{0.7421} = \frac{78.939}{0.7421} \approx 106.37^\circ$$

Questo scostamento residuo rispetto a 120° illustra numericamente il vincolo della discretizzazione biologica: all'aumentare della densità dei neuroni nella popolazione (es. aggiungendo centri intermedi μ ogni 15°), la stima $\hat{x}$ converge asintoticamente al valore reale x .

Compromesso: Offre la massima resilienza ai guasti fisici: anche in presenza di morte neuronale o silenzio anomalo di un nodo, la popolazione conserva la stima metrica complessiva. Lo svantaggio risiede nell'overhead strutturale: richiede un numero di canali sinaptici sensibilmente maggiore.

Paradigma	Meccanismo Chiave	N. Spike	Latenza	Caratteristica Primaria
Rate Coding	Frequenza media di scarica su finestra ΔT	Elevato	Alta	Robustezza al rumore; base per conversioni ANN-SNN.
Temporal (TTFS)	Istante temporale esatto del primo impulso	Minimo (≈ 1)	Minima	Consumi quasi nulli; vulnerabile al jitter hardware.
Population	Vettore di attivazione di un pool distribuito	Medio	Bassa	Ridondanza biologica; resilienza al guasto dei singoli nodi.

Table 1: Confronto sinottico dei protocolli di codifica del segnale in architetture neuromorfiche.

3 Modelli Matematici del Neurone Spiking

Mentre prima abbiamo visto i vari paradigmi di interpretazione della comunicazione tra i vari neuroni, ora dobbiamo capire come i neuroni stessi decidano o meno di attivarsi. Per fare ciò dobbiamo analizzare l'astrazione matematica del neurone. esistono vari modelli anche se il più utilizzato è **LIF**:

3.1 Il Modello Leaky Integrate-and-Fire (LIF)

Il modello LIF è il "cavallo di battaglia" delle SNN moderne per l'IA. Può essere descritto come un circuito RC (resistore-condensatore) in parallelo.

3.1.1 Spiegazione Biofisica Della Catena di Trasmissione Sinaptica

Per chiarire l'astrazione operata dai modelli computazionali delle SNN rispetto alla fisiologia biologica, è essenziale tracciare il ciclo bioelettrochimico completo che governa la comunicazione unidirezionale tra un neurone emettitore (Neurone A, pre-sinaptico) e un neurone ricevente (Neurone B, post-sinaptico), immersi nella matrice extracellulare.

I Componenti Fisici e Molecolari del Neurone Biologico

Prima di analizzare la dinamica temporale dello spike e la trasmissione sinaptica, è opportuno inventariare i componenti strutturali e molecolari che costituiscono l'"hardware" bioelettrochimico di un neurone:

- **Doppio Strato Fosfolipidico (La Membrana):** Una barriera lipidica spessa pochi nanometri che separa fisicamente il citoplasma interno dal fluido extracellulare. Impermeabile agli ioni, funge da dielettrico, trasformando la membrana in un **condensatore microscopico** (C) capace di immagazzinare carica elettrica.
- **Canali Ionici Passivi o di Fuga (*Leak Channels*):** Pori proteici sempre aperti (principalmente selettivi per il potassio K^+) che permettono un flusso frenato ma costante di ioni attraverso la parete, agendo fisicamente come un **resistore di dispersione** (R).
- **La Pompa Sodio-Potassio (Na^+/K^+ -ATPasi):** Un motore molecolare attivo che consuma energia metabolica (ATP) per espellere continuamente 3 ioni Na^+ e pompare dentro 2 ioni K^+ . Mantiene i gradienti di concentrazione chimica e stabilisce il livello energetico basale o **potenziale di riposo** ($V_{rest} \approx -70$ mV).
- **Canali Voltaggio-Dipendenti (Na^+ e K^+):** Porte ioniche intelligenti dislocate lungo il soma e l'assone. Si aprono o chiudono automaticamente in risposta a variazioni locali della tensione di membrana, fungendo da interruttori non lineari responsabili della generazione rapida dello spike.

- **Canali del Calcio Voltaggio-Dipendenti (VGCC):** Canali localizzati esclusivamente sulla punta terminale dell'assone. Si attivano all'arrivo dell'onda di tensione elettrica, permettendo l'ingresso di ioni Ca^{2+} che fungono da innesco chimico.
- **Vescicole Sinaptiche e Neurotrasmettitori (es. Glutammato):** Minuscole sacche lipidiche accumulate nel terminale pre-sinaptico, riempite di molecole chimiche messaggere pronte a essere riversate nella fessura sinaptica.
- **Recettori Post-Sinaptici (AMPA/NMDA):** Proteine recettrici presenti sui dendriti del neurone ricevente. Riconoscono e legano il glutammato rilasciato, spalancando i cancelli per l'afflusso di ioni Na^+ e traducendo il segnale chimico nella corrente d'ingresso $I_{\text{syn}}(t)$.

1. Genesi e Propagazione dell'Impulso nel Neurone A

La dinamica ha inizio nel corpo cellulare (soma) del Neurone A:

1. **Integrazione e Soglia Critica:** Flussi ionici depolarizzanti portano il potenziale di membrana locale a raggiungere la soglia di attivazione (trasportando ioni Na^+):

$$V_m^A(t) \geq V_{\text{th}} \approx -50 \text{ mV}$$

2. **Potenziale d'Azione (Inversione di Polarità):** Il superamento di tale valore sblocca istantaneamente i canali voltaggio-dipendenti del sodio (Na^+). Il massiccio influsso di ioni Na^+ inverte bruscamente la polarità della membrana fino a raggiungere circa $+30 \text{ mV}$.
3. **Reset e Ripristino della Membrana di A:** Raggiunto il picco positivo, i canali del sodio si inattivano e si aprono i canali rapidi del potassio (K^+), espellendo ioni K^+ verso l'ambiente extracellulare locale. Questa fuoriuscita di cariche positive fa crollare il potenziale verso il valore basale:

$$V_m^A(t^+) = V_{\text{reset}} \approx -70 \text{ mV}$$

Nel frattempo, l'inversione di tensione iniziale genera un'onda elettrica depolarizzante che si propaga lungo l'assone fino alla terminazione pre-sinaptica.

2. Trasduzione Elettrochimica tramite Calcio (Ca^{2+}) e Rilascio Vescicolare

Quando il fronte d'onda elettrico a $+30 \text{ mV}$ raggiunge il terminale assonale del Neurone A, si attiva l'interfaccia di conversione tra segnale elettrico e modulazione chimica:

- **Apertura dei Canali Ca^{2+} :** La depolarizzazione terminale apre i canali del calcio voltaggio-dipendenti (VGCC).
- **Ruolo di Innesco del Calcio:** Data l'elevata concentrazione di calcio all'esterno della cellula (circa 10^4 volte superiore rispetto all'ambiente citoplasmatico), gli ioni Ca^{2+} si precipitano all'interno del bottone sinaptico. Il calcio agisce come catalizzatore biomeccanico: legandosi a specifici sensori proteici (sinaptotagmina e complesso SNARE), innesca la fusione delle vescicole sinaptiche con la membrana esterna (*esocitosi*).
- **Emissione di Neurotrasmettitore:** Le vescicole riversano quantità discrete di neurotrasmettitore eccitatorio (tipicamente **glutammato**) nella fessura sinaptica, uno spazio intercellulare di circa 20 nm .

3. Ricezione e Generazione della Corrente nel Neurone B (I_{syn})

Le molecole di glutammato diffondono lungo la fessura sinaptica e si legano ai recettori post-sinaptici (AMPA e NMDA) disposti sui dendriti del Neurone B:

- Il legame recettore-ligando causa l'apertura selettiva di canali ionici che consentono un afflusso diretto di ioni Na^+ (e parzialmente Ca^{2+}) dal fluido extracellulare all'interno del Neurone B.
- Questo flusso di cariche positive in ingresso costituisce la **corrente sinaptica** $I_{\text{syn}}(t)$.

- La membrana del Neurone B accumula nel tempo tale carica secondo la propria costante di tempo τ_m :

$$\tau_m \frac{dV_m^B(t)}{dt} = -[V_m^B(t) - V_{\text{rest}}] + R \cdot I_{\text{syn}}(t)$$

Se l'apporto di corrente $I_{\text{syn}}(t)$ (prodotto da uno o più spike sincroni) è sufficientemente intenso da superare le perdite resistive (*leak* mediato dall'efflusso di K^+), anche il potenziale $V_m^B(t)$ raggiungerà la soglia critica V_{th} , propagando il segnale ai nodi successivi della rete.

4. Chiusura del Ciclo: Riciclo del Neurotrasmettitore ed Estrusione del Calcio

Affinché la sinapsi mantenga risoluzione temporale e non rimanga bloccata in uno stato di saturazione o eccitotossicità, l'ambiente di trasmissione viene bonificato nell'arco di pochi millisecondi:

1. **Rimozione del Ca^{2+} Intracellulare:** Gli ioni calcio all'interno del terminale di A vengono rapidamente sequestrati nel reticolo endoplasmatico ed espulsi all'esterno tramite pompe attive ATP-dipendenti (PMCA) e scambiatori sodio-calcio (NCX). L'arresto del flusso di Ca^{2+} blocca immediatamente l'esocitosi di ulteriori vescicole.
2. **Ricaptazione del Glutammato (*Reuptake*):** Il glutammato presente nella fessura non decade passivamente, ma viene attivamente rimosso tramite trasportatori di membrana dedicati (EAAT, *Excitatory Amino Acid Transporters*) situati sia sulla membrana pre-sinaptica sia sulle cellule gliali (astrociti) circostanti.
3. **Ciclo Glutammato-Glutamina ed Endocitosi Vescicolare:**
 - Negli astrociti, il glutammato assorbito viene convertito enzimaticamente in **glutamina** (molecola inerte e priva di attività neurotrasmettitoriale), ritrasferita al neurone pre-sinaptico e qui riconvertita in glutammato per via enzimatica (tramite glutaminasi).
 - Parallelamente, la membrana del terminale assonale di A recupera le componenti lipidiche delle vescicole fuse tramite *endocitosi*.
 - Trasportatori vescicolari (VGLUT) sfruttano un gradiente protonico per reimballare attivamente il glutammato riciclato all'interno delle nuove vescicole, ripristinando la riserva di quanti pronta per lo scatto successivo.

Mappatura nel Modello Computazionale SNN: Nelle Spiking Neural Networks per l'Embodied AI, simulare ogni singola reazione chimica (l'influsso locale di Ca^{2+} , la fusione meccanica delle vescicole, la diffusione libera del glutammato e il suo riciclo tramite astrociti) comporterebbe un onere computazionale insostenibile per il controllo robotico in tempo reale. Pertanto, l'intera catena biofisica viene sintetizzata in una formulazione matematica compatta:

$$I_{\text{syn}}^B(t) = \sum_j w_{jB} \sum_k \kappa(t - t_j^k)$$

Questa espressione scompone l'effetto di ogni impulso incidente in tre elementi operativi distinti:

- **I treni di spike pre-sinaptici (t_j^k):** L'indice j scorre su tutti i neuroni a monte connessi al Neurone B, mentre t_j^k rappresenta il momento esatto (k -esimo istante temporale) in cui il neurone j ha emesso uno spike binario.
- **Il peso sinaptico scalare (w_{jB}):** Riassume in un unico parametro apprendibile la “forza” complessiva del canale di comunicazione tra il nodo j e il nodo B. A livello biologico condensa contemporaneamente:
 1. L'efficienza pre-sinaptica (quante molecole di glutammato vengono liberate a fronte di uno spike);
 2. La sensibilità post-sinaptica (quanti recettori e canali del sodio si aprono sulla membrana del neurone ricevente).

Un valore elevato di w_{jB} significa che il singolo spike causerà un consistente afflusso di carica positiva, mentre un valore prossimo a zero rende il passaggio di segnale quasi ininfluente.

- **Il nucleo di risposta temporale ($\kappa(t - t_j^k)$):** Quando il neurotrasmettitore si lega ai recettori, i canali ionici non si aprono e chiudono all'istante infinitesimo; mostrano una dinamica fluida con una fase rapida di salita e una coda di decadimento esponenziale. La funzione $\kappa(\Delta t)$ modella proprio questa transitorietà: quantifica quanta corrente continua a scorrere a distanza di Δt millisecondi dall'arrivo dello spike.

Nel caso più elementare ed efficiente per il calcolo parallelo su GPU/NPU (modello a corrente istantanea o impulsiva), tale nucleo viene approssimato con una delta di Dirac:

$$\kappa(t - t_j^k) = \delta(t - t_j^k)$$

In questa configurazione semplificata, ogni spike emesso all'istante t inietta immediatamente una quantità discreta di carica proporzionale a w_{jB} , delegando interamente la persistenza temporale e la memoria della scarica alla sola costante di decadimento di membrana τ_m del neurone ricevente.




Figure 1: Dettaglio del meccanismo di trasduzione bioelettrochimica (Fasi 2-5). L'arrivo del potenziale d'azione sblocca i canali VGCC, permettendo l'ingresso di Ca^{2+} . Quest'ultimo funge da interruttore meccanico, spingendo le vescicole a rilasciare Glutammato nella fessura (esocitosi). Il neurotrasmettitore si lega ai recettori post-sinaptici, aprendo i canali ionici che generano la corrente I_{syn} sotto forma di flusso di Na^+ nel Neurone B. Parallelamente, meccanismi di *reuptake* ed espulsione ionica "bonificano" l'ambiente per il ciclo successivo.

3.1.2 Derivazione Analitica tramite la Legge di Kirchhoff

Per comprendere l'origine fisica dell'equazione differenziale del neurone LIF, si applica il primo principio di Kirchhoff (legge dei nodi) alla membrana cellulare, modellata come la superficie di separazione tra il citoplasma interno e il liquido extracellulare.

In ogni istante t , la carica elettrica non può accumularsi indefinitamente in un punto ideale senza generare tensione. Pertanto, la corrente sinaptica complessiva $I_{\text{syn}}(t)$ che entra nella cellula (portata dall'apertura dei canali sinaptici a seguito degli spike in arrivo) deve necessariamente ripartirsi in due soli percorsi fisici possibili:

$$I_{\text{syn}}(t) = I_C(t) + I_R(t)$$

Analizziamo il significato fisico e il ruolo biologico dei due contributi:

- **Corrente Capacitiva di Accumulo ($I_C(t)$) — La Memoria di Breve Termine del Neurone:** La membrana fosfolipidica è un isolante sottilissimo (3–4 nm) che impedisce agli ioni di attraversarla

liberamente, comportandosi come un condensatore elettrico di capacità C . Poiché la carica accumulata sulle armature è $Q(t) = C \cdot V_m(t)$ (potenziale che cambia nel tempo), la corrente capacitiva corrisponde alla velocità con cui la carica netta si deposita sulle superfici della membrana nel tempo:

$$I_C(t) = \frac{dQ(t)}{dt} = C \frac{dV_m(t)}{dt}$$

Cosa rappresenta nella realtà: È il flusso di ioni positivi (principalmente Na^+ e Ca^{2+}) che entrano e si addossano sulla faccia interna della membrana. Più questo flusso è intenso, più rapida è la variazione della tensione cellulare $\frac{dV_m(t)}{dt}$. È questo termine a conferire al neurone la capacità di integrare temporalmente più ingressi distinti.

- **Corrente Resistiva di Dispersione ($I_R(t)$) — La Perdita (*Leak*) per Dissipazione Passiva:** La membrana non è un isolante perfetto: include canali ionici passivi (detti canali di fuga o *leak channels*, selettivi per il potassio K^+) che rimangono costantemente pervi. La legge di Ohm applicata a questa barriera stabilisce che la corrente attraverso tali pori è guidata non dalla tensione assoluta, ma dal dislivello elettrochimico rispetto al punto di equilibrio naturale della cellula ($V_{\text{rest}} \approx -70$ mV):

$$I_R(t) = \frac{V_m(t) - V_{\text{rest}}}{R}$$

dove R è la resistenza ohmica totale offerta dalla membrana.

Cosa rappresenta nella realtà: Se il neurone è stato eccitato e il potenziale sale al di sopra di V_{rest} (ad esempio a -60 mV), la differenza di potenziale spinge gli ioni potassio K^+ a fuoriuscire spontaneamente dalla cellula verso l'esterno. Questo flusso di fuga scarica progressivamente la membrana, impedendo che uno stimolo vecchio rimanga memorizzato per sempre. Se lo stimolo cessa, $I_R(t)$ riporta inevitabilmente il neurone in quiete a V_{rest} .

Sostituendo le due definizioni fisiche nel bilancio dei flussi al nodo della membrana:

$$I_{\text{syn}}(t) = C \frac{dV_m(t)}{dt} + \frac{V_m(t) - V_{\text{rest}}}{R}$$

Questa formulazione bilancia già le correnti (in Ampere), ma per isolare la velocità di variazione del potenziale $\frac{dV_m(t)}{dt}$ si moltiplicano entrambi i membri per la resistenza R :

$$R I_{\text{syn}}(t) = R \cdot C \frac{dV_m(t)}{dt} + [V_m(t) - V_{\text{rest}}]$$

Notiamo che il prodotto $R \cdot C$ possiede le dimensioni fisiche di un intervallo temporale:

$$[R] \cdot [C] = \left(\frac{\text{V}}{\text{A}} \right) \cdot \left(\frac{\text{A} \cdot \text{s}}{\text{V}} \right) = \text{s} \quad (\text{o millisecondi, ms})$$

Definendo tale grandezza come **costante di tempo di membrana** $\tau_m = R \cdot C$, l'equazione viene riordinata nella forma canonica del modello LIF:

$$\tau_m \frac{dV_m(t)}{dt} = -[V_m(t) - V_{\text{rest}}] + R I_{\text{syn}}(t)$$

Significato Computazionale: L'equazione finale descrive un compromesso continuo tra due forze opposte:

1. **La forza motrice esterna ($R I_{\text{syn}}(t)$):** Tenta di spingere il neurone verso l'alto per raggiungere la soglia di scarica V_{th} , convertendo la corrente in ingresso in una deflessione di tensione scalata dalla resistenza R .
2. **La forza elastica di ripristino ($-[V_m(t) - V_{\text{rest}}]$):** Tenta costantemente di dissipare l'energia assorbita e ricondurre il sistema all'azzeramento basale.

Il parametro τ_m quantifica la "finestra di memoria utile": un neurone con τ_m elevato trattiene la carica a lungo e integra spike distanti nel tempo; un neurone con τ_m ridotto dimentica quasi istantaneamente gli stimoli passati, rispondendo solo a eventi sincroni estremamente ravvicinati.




Figure 2: Circuito RC equivalente di membrana del modello LIF. La membrana lipidica funge da condensatore C in parallelo con i canali ionici passivi modellati dal resistore di perdita R in serie con la sorgente elettromotrice V_{rest} .




Figure 3: Dinamica del potenziale di membrana in un neurone Leaky Integrate-and-Fire (LIF). La corrente sinaptica in ingresso integra il potenziale (linea blu). Quando si raggiunge la soglia V_{th} (linea rossa tratteggiata), viene emesso uno spike asincrono, e il potenziale viene resettato forzatamente a V_{reset} . Segue un breve periodo refrattario (area grigia) durante il quale l'integrazione è sospesa.

Formula finale:

$$\tau_m \frac{dV_m(t)}{dt} = -[V_m(t) - V_{rest}] + R I_{syn}(t)$$

dove:

- $V_m(t)$ rappresenta il **potenziale di membrana istantaneo** del neurone (misurato in millivolt, mV). Costituisce la variabile di stato interna fondamentale: quantifica la differenza di potenziale elettrico transmembrana tra il citoplasma intracellulare e il fluido extracellulare all'istante t .
- $\frac{dV_m(t)}{dt}$ denota la **derivata temporale** del potenziale, ovvero la velocità istantanea di carica o scarica elettrica della membrana.
- $\tau_m = R \cdot C$ è la **costante di tempo di membrana** (espressa in millisecondi, ms). Regola l'inerzia temporale del sistema: modula la rapidità con cui la carica accumulata si disperde per perdita passiva (*leak*) attraverso i canali ionici.
- $-[V_m(t) - V_{rest}]$ costituisce il **termine di dispersione passiva** (*leakage term*). Agisce come una forza di richiamo elastica: in assenza di stimoli esterni, tende a riportare esponenzialmente il potenziale verso il valore di equilibrio asintotico.
- V_{rest} è il **potenziale di riposo** (tipicamente -70 mV), corrispondente al livello energetico basale della membrana non perturbata.

- R rappresenta la **resistenza passiva di membrana** (espressa in megaohm, $M\Omega$), che quantifica l'opposizione al passaggio ionico attraverso la parete fosfolipidica.
- $I_{\text{syn}}(t)$ è la **corrente sinaptica complessiva** in ingresso (espressa in nanoampere, nA), derivante dalla sommatoria pesata degli spike pre-sinaptici incidenti.

L'emissione dello spike e il conseguente ripristino avvengono secondo la regola di soglia non differenziabile (V_{th} è il potenziale di soglia sotto il quale non verrà emesso lo spike):

$$\text{Se } V_m(t) \geq V_{\text{th}} \implies \begin{cases} S(t) = 1 & (\text{Emissione dello spike}) \\ V_m(t^+) = V_{\text{reset}} & (\text{Reset forzato}) \end{cases}$$

Esempio Pratico e Tracciamento Numerico: Si consideri un neurone LIF caratterizzato dai seguenti parametri biofisici standard:

- $V_{\text{rest}} = -70$ mV, $V_{\text{th}} = -50$ mV, $V_{\text{reset}} = -70$ mV; (semplicemente a quanto V_{rest} si resetta ad ogni ciclo)
- $\tau_m = 10$ ms, $R = 10$ $M\Omega$.

All'istante iniziale $t = 0$ ms, il neurone si trova a riposo ($V_m(0) = -70$ mV). A partire da questo momento, viene applicata una corrente sinaptica costante $I_{\text{syn}} = 2.5$ nA.

Risolviendo l'equazione differenziale a gradino, l'evoluzione analitica assume la forma:

$$V_m(t) = V_{\text{rest}} + R I_{\text{syn}} \left(1 - \exp\left(-\frac{t}{\tau_m}\right) \right)$$

Notiamo che il termine asintotico a regime vale:

$$V_{\infty} = V_{\text{rest}} + R I_{\text{syn}} = -70 \text{ mV} + (10 \text{ } M\Omega \cdot 2.5 \text{ nA}) = -70 + 25 = -45 \text{ mV}$$

$V_{\infty} = V_{\text{rest}} + R I_{\text{syn}}$ rappresenta il **potenziale asintotico a regime**: costituisce il valore limite a cui il potenziale di membrana $V_m(t)$ convergerebbe per $t \rightarrow \infty$ sotto l'azione della corrente costante I_{syn} , in assenza di un meccanismo di soglia.

1. **Al tempo $t = 5$ ms ($t = 0.5 \tau_m$):**

$$V_m(5) = -70 + 25 \cdot (1 - e^{-0.5}) = -70 + 25 \cdot (1 - 0.6065) = -70 + 9.84 = -60.16 \text{ mV}$$

Il potenziale è salito di quasi 10 mV, ma $V_m(5) < -50$ mV: la soglia non è superata ($S(5) = 0$).

2. **Al tempo $t = 10$ ms ($t = 1.0 \tau_m$):**

$$V_m(10) = -70 + 25 \cdot (1 - e^{-1.0}) = -70 + 25 \cdot (1 - 0.3679) = -70 + 15.80 = -54.20 \text{ mV}$$

La carica continua ad accumularsi, ma la dispersione passiva ne rallenta progressivamente la crescita ($S(10) = 0$).

3. **Istante esatto dello spike (t_{fire}):** Imponendo $V_m(t_{\text{fire}}) = V_{\text{th}} = -50$ mV:

$$-50 = -70 + 25 \cdot \left(1 - e^{-\frac{t_{\text{fire}}}{10}} \right) \implies 20 = 25 \cdot \left(1 - e^{-\frac{t_{\text{fire}}}{10}} \right)$$

$$0.80 = 1 - e^{-\frac{t_{\text{fire}}}{10}} \implies e^{-\frac{t_{\text{fire}}}{10}} = 0.20 \implies -\frac{t_{\text{fire}}}{10} = \ln(0.20) \approx -1.6094$$

$$t_{\text{fire}} = 10 \cdot 1.6094 \approx 16.09 \text{ ms}$$

All'istante $t = 16.09$ ms, il potenziale tocca quota -50 mV: il neurone emette un impulso binario $S(16.09) = 1$, e il potenziale interno crolla istantaneamente al valore di reset $V_m(16.09^+) = -70$ mV, azzerando la memoria di carica accumulata e riavviando il ciclo di integrazione.

La condizione di spiking è definita discontinuamente:

$$\text{Se } V_m(t) \geq V_{\text{th}} \implies \begin{cases} \text{Emetti Spike } S(t) = 1 \\ V_m(t^+) = V_{\text{reset}} \end{cases}$$

Dopo lo spike, il neurone entra spesso in un periodo refrattario durante il quale non può generare altri impulsi.

3.2 Modelli Avanzati e Conduttanza-Dipendenti

Per applicazioni che richiedono maggiore realismo fisiologico, si utilizzano modelli più complessi:

- **Modello di Hodgkin-Huxley (1952):** Descrive dettagliatamente i canali ionici (Sodio, Potassio) tramite quattro equazioni differenziali non lineari accoppiate. È il *gold standard* per la biofisica, ma computazionalmente proibitivo per reti di grandi dimensioni.
- **Modello di Izhikevich:** Combina la ricchezza dinamica di Hodgkin-Huxley (*bursting, chattering*, adattamento) con una complessità computazionale quasi paragonabile al LIF, utilizzando un sistema di due equazioni differenziali del primo ordine.

4 Sinapsi e Modelli di Corrente Sinaptica

I neuroni non sono isolati; comunicano attraverso le sinapsi, che modulano l'intensità del segnale trasmesso. Nelle SNN, il peso sinaptico w_{ij} determina l'ampiezza dell'effetto che uno spike del neurone pre-sinaptico i ha sul neurone post-sinaptico j .

Quando uno spike pre-sinaptico arriva al tempo t_i^k , genera una corrente sinaptica $I_{syn}(t)$ nel neurone post-sinaptico. Esistono due modellizzazioni principali:

4.1 Modello Delta-Current:

Lo spike genera un impulso istantaneo di corrente modellato tramite una delta di Dirac. Il potenziale di membrana compie un salto discontinuo nel momento esatto di arrivo dello spike:

$$V_j(t^+) = V_j(t^-) + w_{ij}$$

dove:

- $V_j(t^-)$ rappresenta il **potenziale di membrana del neurone post-sinaptico j un istante infinitesimo prima** dell'arrivo dello spike pre-sinaptico.
- $V_j(t^+)$ rappresenta il **potenziale di membrana del neurone post-sinaptico j un istante infinitesimo dopo** l'integrazione dell'impulso.
- w_{ij} è il **peso sinaptico** scalare associato alla connessione tra il neurone pre-sinaptico i e il neurone post-sinaptico j ; definisce l'ampiezza dell'incremento istantaneo di tensione indotto dall'evento.

È il modello computazionalmente più economico, ampiamente impiegato nelle architetture SNN per deep learning.

4.2 Modello a Conduttanza (Esponenziale):

A differenza del modello a delta di corrente (in cui il potenziale subisce un salto discontinuo artificiale), questo approccio riproduce fedelmente l'interazione biochimica reale. Il processo si articola in due dinamiche distinte e concatenate:

1. **Fase di Apertura e Decadimento della Conduttanza (g_{syn}):** All'arrivo di uno spike al tempo t_i^k , le molecole di neurotrasmettitore saturano i recettori post-sinaptici in frazioni di millisecondo. Di conseguenza, la sola **permeabilità della membrana (la conduttanza g_{syn}) compie un salto istantaneo** proporzionale al peso w_{ij} . Successivamente, i canali ionici si richiudono progressivamente, provocando un **decadimento esponenziale** della conduttanza verso lo zero.

Tale dinamica è governata dall'equazione differenziale lineare del primo ordine:

$$\tau_{syn} \frac{dg_{syn}(t)}{dt} = -g_{syn}(t) + w_{ij} \sum_k \delta(t - t_i^k)$$

dove:

- $g_{\text{syn}}(t)$ rappresenta la **conduttanza sinaptica istantanea** (misurata in siemens, S, o nanosiemens, nS). È l'inverso della resistenza ($g = 1/R$) e quantifica la pervietà complessiva dei canali ionici attivati: un valore nullo indica canali completamente serrati, mentre un valore elevato indica un'ampia apertura al transito ionico.
- $\frac{dg_{\text{syn}}(t)}{dt}$ denota la **derivata temporale della conduttanza**, che descrive la velocità istantanea di apertura o chiusura dei pori proteici.
- τ_{syn} è la **costante di tempo sinaptica** (tipicamente compresa tra 2 e 5 ms); definisce la rapidità con cui il neurotrasmettitore viene metabolizzato e i canali si richiudono.
- $-g_{\text{syn}}(t)$ costituisce il **termine di decadimento spontaneo**, responsabile del rilassamento esponenziale della conduttanza al livello basale di quiete.
- w_{ij} è l'**efficacia sinaptica** (peso), che modella l'incremento impulsivo di conduttanza generato da ciascun singolo evento pre-sinaptico (proporzionale al numero di canali sbloccati).
- $\sum_k \delta(t - t_i^k)$ rappresenta il **treno di spike pre-sinaptici** discreti emessi dal neurone afferente i , modellati analiticamente come impulsi ideali di Dirac centrati negli istanti t_i^k .

2. **Fase di Iniezione di Corrente ed Evoluzione Continua del Potenziale (V_j):** Con i canali ionici temporaneamente aperti ($g_{\text{syn}}(t) > 0$), gli ioni extracellulari migrano verso l'interno spinti dal gradiente elettrochimico, generando un flusso reale di corrente $I_{\text{syn}}(t)$. Tale corrente fluisce verso la capacità di membrana C , provocando un **innalzamento continuo e graduale del potenziale** (noto come potenziale post-sinaptico eccitatorio, *EPSP*): il potenziale non compie salti discontinui, ma traccia una curva liscia che raggiunge un picco arrotondato per poi ridiscendere verso il riposo al richiudersi dei canali. L'intensità del flusso di corrente risponde alla legge di Ohm generalizzata per conduttanze variabili:

$$I_{\text{syn}}(t) = g_{\text{syn}}(t) (V_j(t) - E_{\text{rev}})$$

dove:

- $I_{\text{syn}}(t)$ è la **corrente sinaptica risultante in un istante di tempo** (espressa in nanoampere, nA) che penetra nel citoplasma del neurone post-sinaptico j .
- $V_j(t)$ è il **potenziale di membrana istantaneo** del neurone ricevente.
- E_{rev} è il **potenziale di inversione** (*reversal potential*): definisce se l'effetto della sinapsi è **eccitatorio** o **inibitorio**. Rappresenta il valore limite verso cui la corrente sinaptica tenta di trascinare il potenziale di membrana:
 - **Sinapsi Eccitatoria** ($E_{\text{rev}} > V_{\text{th}}$, tipicamente ≈ 0 mV): la corrente depolarizza la membrana, spingendo $V_j(t)$ verso l'alto in direzione della soglia di sparo.
 - **Sinapsi Inibitoria** ($E_{\text{rev}} < V_{\text{th}}$, tipicamente ≈ -70 – -80 mV): la corrente iperpolarizza la membrana o la frena verso il basso, allontanando $V_j(t)$ dalla soglia e impedendo l'emissione dello spike.
- $(V_j(t) - E_{\text{rev}})$ rappresenta la **forza motrice elettrochimica** (*driving force*), ovvero il potenziale effettivo che spinge gli ioni ad attraversare la membrana attraverso i canali aperti.

ATTENZIONE: non ci interessa calcolare il numero di Na^+ nel neurone dato che loro sono solo il mezzo, quello che ci interessa è l'intensità di corrente in un determinato istante di tempo.

5 Apprendimento nelle Reti Neuromorfiche

Nelle Reti Neurali Artificiali (ANN) convenzionali, l'apprendimento è un processo puramente algebrico: l'aggiornamento di una matrice di pesi continui per minimizzare una funzione di costo globale. Nelle Spiking Neural Networks (SNN), l'apprendimento deve confrontarsi sia con l'ispirazione biologica sia con le severe sfide matematiche imposte dalla natura discontinua degli spike.

5.1 Fondamenti Biologici: Cosa significa fisicamente "imparare"?

Prima di analizzare gli algoritmi, è fondamentale chiarire a cosa corrisponde fisicamente la variazione del peso sinaptico Δw_{ij} nel cervello. L'apprendimento biologico, noto come **plasticità sinaptica**, è la capacità delle sinapsi di rafforzare o indebolire la propria efficacia nel tempo.

Fisicamente, una sinapsi "più forte" (un w_{ij} maggiore) significa che un singolo spike in arrivo genererà un potenziale post-sinaptico (EPSP) più alto, avvicinando maggiormente il neurone ricevente alla soglia di sparo. Questo aumento di efficacia avviene attraverso due meccanismi molecolari principali:

1. **Modifiche Post-sinaptiche (Inserimento di Recettori):** Quando una sinapsi viene potenziata (Long-Term Potentiation, **LTP**), la cellula ricevente inserisce fisicamente un numero maggiore di recettori AMPA (i responsabili dell'apertura di un canale ionico, un recettore AMPA ha il suo canale) sulla propria membrana dendritica. Al successivo arrivo del glutammato, si apriranno più canali simultaneamente: la conduttanza g_{syn} sarà maggiore, entreranno più ioni Sodio (Na^+), e il potenziale V_m subirà un'impennata molto più marcata.
2. **Modifiche Pre-sinaptiche (Rilascio Vescicolare):** Il potenziamento può anche indurre il terminale pre-sinaptico a rilasciare un numero maggiore di vescicole di neurotrasmettitore a parità di ingresso di Calcio (Ca^{2+}).

Al contrario, se una sinapsi si rivela inutile o controproducente, i recettori vengono "inghiottiti" (endocitosi) e rimossi dalla membrana (Long-Term Depression, **LTD**): il peso w_{ij} diminuisce e la sinapsi viene silenziata.

Gli algoritmi di apprendimento per le SNN tentano di replicare o ottimizzare questa variazione dei pesi, e si dividono in tre paradigmi principali.

5.2 1. Apprendimento Non Supervisionato: Plasticità Ebbiana e STDP

Questo paradigma si basa sulle regole biologiche di auto-organizzazione locale, riassunte dal celebre postulato di Donald Hebb (1949): "*Neurons that fire together, wire together*" (Neuroni che scaricano insieme, si legano insieme). Nelle SNN temporali, questa regola prende la forma matematica della **Spike-Timing-Dependent Plasticity (STDP)**.

La STDP stabilisce che non basta scaricare "insieme", ma è fondamentale l'ordine causale temporale. La variazione del peso Δw_{ij} dipende rigorosamente dalla distanza temporale $\Delta t = t_{\text{post}} - t_{\text{pre}}$ tra lo spike del neurone afferente (t_{pre}) e lo spike del neurone ricevente (t_{post}).

Il rilevatore di coincidenze biologico (Recettori NMDA): Biologicamente, la STDP è resa possibile dai recettori NMDA, che fungono da *coincidence detectors* (rilevatori di coincidenza). Essi inviano il segnale di creare più recettori AMPA per far entrare ulteriore Calcio (Ca^{2+}) **solo se si verificano due condizioni contemporaneamente:** il glutammato si lega (segnale pre-sinaptico) E la membrana è già fortemente depolarizzata cambiando di tensione (segnale post-sinaptico). Questo massiccio ingresso di Calcio innesca la cascata chimica che inserisce nuovi recettori AMPA (LTP).

Dinamica Molecolare del Calcio e Doppia Scala Temporale dell'LTP: Per comprendere appieno la plasticità sinaptica, è fondamentale non confondere i due ruoli distinti che lo ione Calcio (Ca^{2+}) ricopre sui due versanti della fessura sinaptica:

- **Calcio Pre-sinaptico (Trasmissione Ordinaria):** Penetra nel terminale assonale tramite i canali voltaggio-dipendenti VGCC all'arrivo del potenziale d'azione, fungendo da innesco meccanico esclusivo per l'esocitosi del **glutammato**¹;
- **Calcio Post-sinaptico (Segnale di Apprendimento):** Penetra nella spina dendritica unicamente attraverso i canali NMDA quando questi vengono stappati dalla coincidenza temporale pre-post. In questo contesto, il recettore NMDA agisce unicamente come varco di controllo: è il flusso intracellulare di Ca^{2+} a operare come secondo messaggero, attivando specifiche cascate enzimatiche che dirigono materialmente l'inserimento di nuovi recettori AMPA.

¹Si noti la differenza con la *glutamina*, che rappresenta invece la forma inerte riciclata dagli astrociti e reintrodotta nel neurone per essere riconvertita in neurotrasmettitore attivo.




Figure 4: Schema del doppio ruolo del Calcio (Ca^{2+}) nella sinapsi. **In alto (Pre-sinaptico):** il calcio entra attraverso i canali VGCC e agisce da innesco meccanico per rilasciare il glutammato. **In basso (Post-sinaptico):** il calcio entra attraverso i canali NMDA (solo se stappati) e funge da messaggero enzimatico per l'inserimento di nuovi recettori AMPA (plasticità sinaptica, LTP).

La conseguente riconfigurazione fisica del peso sinaptico w_{ij} si sviluppa su due distinte scale temporali:

- Fase Rapida (da decine di secondi a pochi minuti) — Reclutamento da riserve:** Il neurone non necessita di sintetizzare nuove proteine nell'immediato; l'attivazione enzimatica mediata dal Ca^{2+} induce la rapida fusione di vescicole intracellulari già cariche di recettori AMPA preformati. Questi vengono esposti e ancorati alla densità post-sinaptica (PSD), aumentando immediatamente la conduttanza g_{syn} e quindi l'ampiezza dell'EPSP;
- Fase Lenta e Consolidamento (da ore a giorni) — Espressione genica e rimodellamento:** Se la stimolazione e l'afflusso di calcio persistono con regolarità, il segnale biochimico si propaga fino al nucleo cellulare, attivando fattori di trascrizione (come CREB). La cellula avvia la sintesi *ex-novo* di complessi proteici e un vero e proprio ingrandimento morfologico della spina dendritica, stabilizzando il peso sinaptico e trasformando la variazione da transitoria a memoria strutturale a lungo termine.

5.2.1 regola matematica di addestramento:

Per tradurre il tutto in formato usabile per ricreare virtualmente questo effetto, la regola di aggiornamento matematica per la finestra di plasticità è:

$$\Delta w = \begin{cases} A_+ \exp\left(-\frac{t_{\text{post}} - t_{\text{pre}}}{\tau_+}\right) & \text{se } t_{\text{post}} > t_{\text{pre}} \quad (\text{LTP: Potenzimento}) \\ -A_- \exp\left(\frac{t_{\text{post}} - t_{\text{pre}}}{\tau_-}\right) & \text{se } t_{\text{post}} < t_{\text{pre}} \quad (\text{LTD: Depression}) \end{cases}$$

Dove A_+, A_- determinano l'ampiezza massima della modifica e τ_+, τ_- le costanti di tempo di decadimento (tipicamente attorno ai 20 ms).

- **Causalità (LTP):** Se il neurone pre-sinaptico spara *poco prima* di quello post-sinaptico ($t_{\text{pre}} < t_{\text{post}}$), significa che ha *contribuito fisicamente* a far salire la tensione verso la soglia. La sinapsi viene premiata e rafforzata. Più i due eventi sono vicini, più l'incremento è esplosivo.
- **Anti-Causalità (LTD):** Se il neurone pre-sinaptico spara *dopo* che il post-sinaptico ha già emesso il suo spike, il suo contributo è arrivato in ritardo ed è stato del tutto inutile. La rete penalizza questa inefficienza deprimendo il peso della sinapsi, risparmiando risorse energetiche.




Figure 5: La finestra della Spike-Timing-Dependent Plasticity (STDP). Se il segnale pre-sinaptico precede lo spike post-sinaptico ($\Delta t > 0$, LTP), la sinapsi viene rafforzata esponenzialmente in funzione della vicinanza temporale. Se il segnale arriva in ritardo ($\Delta t < 0$, LTD), viene depresso. Questa regola asimmetrica permette alla rete di estrarre autonomamente pattern causali temporali, senza alcuna etichetta di supervisione globale.

5.3 2. Supervisione tramite Gradienti Surrogati (Surrogate Gradients)

Mentre la STDP è eccellente per l'estrazione non supervisionata di feature, per addestrare reti neuromorfiche profonde su task specifici (es. guida autonoma, classificazione complessa) è necessario ricorrere alla **Backpropagation (Propagazione all'Indietro del Gradiente)**.

Il Problema del Gradiente Nullo (Dead Neuron Problem): Per applicare la regola della catena del calcolo differenziale (BPTT - Backpropagation Through Time), dobbiamo calcolare la derivata della funzione di attivazione del neurone. Il problema fondamentale delle SNN è che la generazione dello spike è una funzione a gradino di Heaviside:

$$S(t) = \Theta(V_m(t) - V_{\text{th}}) = \begin{cases} 1 & \text{se } V_m(t) \geq V_{\text{th}} \\ 0 & \text{altrimenti} \end{cases}$$

La derivata esatta di questa funzione discontinua è la Delta di Dirac $\delta(V_m - V_{\text{th}})$. Questo significa che la derivata è **zero ovunque** (la curva è piatta), tranne nel punto esatto della soglia dove è infinita. Se proviamo a propagare all'indietro l'errore per correggere i pesi ($\frac{\partial \text{Loss}}{\partial w}$), l'errore viene moltiplicato per zero ad ogni strato. L'algoritmo si blocca immediatamente e i pesi non vengono mai aggiornati.

La Soluzione: Il Gradiente Surrogato: Per superare questo ostacolo matematico, si utilizza una tecnica di *straight-through estimator* (STE) modificato. L'idea è di ingannare l'algoritmo separando il comportamento della rete tra la fase di andata e quella di ritorno:

- **Fase Forward (Inferenza):** Si utilizza l'equazione biofisica esatta e discontinua. I neuroni comunicano solo con spike binari rigidi (0 o 1). La natura neuromorfica a basso consumo è preservata.

- **Fase Backward (Addestramento):** Si sostituisce matematicamente la derivata problematica della funzione di Heaviside con una derivata "surrogata" differenziabile, liscia e definita ovunque.

Un surrogato comune è la derivata di una sigmoide riscalata (Fast Sigmoid) o una funzione triangolare:

$$\frac{\partial S}{\partial V_m} \approx \sigma'(V_m) = \frac{1}{(1 + \alpha|V_m - V_{th}|)^2}$$

dove α è un iperparametro che controlla la larghezza (e quindi la tolleranza) del gradiente attorno alla soglia. Grazie a questa "strada asfaltata" matematica, l'errore può fluire fluidamente a ritroso nel tempo (BPTT) e attraverso i layer, aggiornando i pesi sinaptici w_{ij} . Questa tecnica ha sbloccato l'integrazione delle SNN con i moderni framework di deep learning (PyTorch, JAX), permettendo di ottenere precisioni competitive con le ANN.

Esempio Numerico: Per visualizzare concretamente come opera la sostituzione durante l'ottimizzazione, consideriamo un singolo neurone con una soglia $V_{th} = -50 \text{ mV}$ e supponiamo che a un dato istante il suo potenziale di membrana sia molto vicino alla soglia ma non l'abbia superata:

$$V_m = -50.2 \text{ mV}$$

Supponiamo inoltre che, calcolando la retropropagazione dell'errore globale $\mathcal{L}$, il gradiente in arrivo dagli strati successivi sia $\frac{\partial \mathcal{L}}{\partial S} = -2.0$ (derivata della loss). Applicando la regola della catena per aggiornare un peso in ingresso w , dobbiamo calcolare:

$$\frac{\partial \mathcal{L}}{\partial w} = \frac{\partial \mathcal{L}}{\partial S} \cdot \frac{\partial S}{\partial V_m} \cdot \frac{\partial V_m}{\partial w}$$

Vediamo cosa succede nei due passaggi:

1. **Passo Forward (Fisica Reale):** Il neurone calcola la funzione a gradino di Heaviside reale:

$$S = \Theta(V_m - V_{th}) = \Theta(-50.2 - (-50.0)) = \Theta(-0.2) = 0$$

Poiché la soglia non è stata raggiunta, lo spike emesso è rigorosamente **0**. L'inferenza e la dinamica forward rimangono binarie e fedeli al modello spiking.

2. **Passo Backward (Il Fallimento della Derivata Reale):** Se usassimo la derivata reale della funzione di Heaviside ($\delta(x)$, nulla ovunque tranne sul punto esatto di soglia), avremmo:

$$\left. \frac{\partial S}{\partial V_m} \right|_{\text{reale}} = 0 \implies \frac{\partial \mathcal{L}}{\partial w} = (-2.0) \cdot \mathbf{0} \cdot \frac{\partial V_m}{\partial w} = \mathbf{0}$$

Nonostante il neurone fosse a soli 0.2 mV dallo sparare, l'errore viene azzerato. Il gradiente svanisce e il peso w non riceve alcuna correzione.

3. **Passo Backward (Sostituzione con Gradiente Surrogato):** Nella backpropagation, sostituiamo $\frac{\partial S}{\partial V_m}$ con la derivata di una funzione surrogata liscia (ad esempio una Fast Sigmoid con pendenza $\alpha = 1$):

$$\sigma'(V_m) = \frac{1}{(1 + \alpha|V_m - V_{th}|)^2}$$

Valutando il surrogato nel punto reale $V_m = -50.2 \text{ mV}$:

$$\left. \frac{\partial S}{\partial V_m} \right|_{\text{surrogato}} = \frac{1}{(1 + 1 \cdot |-0.2|)^2} = \frac{1}{(1.2)^2} = \frac{1}{1.44} \approx \mathbf{0.694}$$

Sostituendo questo valore non nullo nella regola della catena:

$$\frac{\partial \mathcal{L}}{\partial w} \approx (-2.0) \cdot \mathbf{0.694} \cdot \frac{\partial V_m}{\partial w} = -1.388 \cdot \frac{\partial V_m}{\partial w} \neq \mathbf{0}$$

In sintesi: durante l'esecuzione in avanti il neurone rimane un dispositivo discreto a eventi (emette 0), ma durante il calcolo all'indietro il framework tratta il neurone come se fosse "quasi riuscito a sparare", lasciando fluire un gradiente utile per correggere w nella direzione corretta.

5.4 3. Conversione da ANN a SNN

Un approccio alternativo all'addestramento diretto con gradienti surrogati è la **conversione da ANN a SNN**. Invece di ottimizzare la rete nello spazio temporale discreto degli spike, si sfrutta un'equivalenza asintotica: l'algebra continua di una rete tradizionale può essere fedelmente riprodotta da una rete spiking se l'informazione viene codificata nella **frequenza media di scarica** (*Rate Coding*) lungo una finestra temporale sufficientemente estesa.

Perché due modelli così diversi possono equivalersi? A prima vista i due paradigmi sembrano incompatibili: una ANN computa una moltiplicazione statica continua in un unico istante, mentre una SNN scambia impulsi binari distribuiti nel tempo. L'anello di congiunzione è il comportamento del neurone **Integrate-and-Fire (IF)** senza perdite passive (*non-leaky*), alimentato a monte da un treno di spike.

Consideriamo l'operazione fondamentale del neurone j -esimo in una ANN con attivazione ReLU:

$$a_j^{\text{ANN}} = \max \left(0, \sum_i W_{ji} a_i^{\text{ANN}} + b_j \right)$$

Nel neurone IF della controparte SNN, il potenziale di membrana $V_j(t)$ accumula nel tempo T gli spike binari in ingresso $S_i(t) \in \{0, 1\}$ pesati da W_{ji} :

$$V_j(T) = V_j(0) + \sum_{t=1}^T \left(\sum_i W_{ji} S_i(t) + I_{\text{bias}} \right) - V_{\text{th}} \sum_{t=1}^T S_j(t)$$

dove l'ultimo termine rappresenta il meccanismo di reset (nello specifico, *reset-by-subtraction*, in cui ogni volta che si emette uno spike si sottrae esattamente V_{th} dal potenziale anziché azzerarlo, preservando il residuo di carica accumulato).

Dividendo l'intera equazione per il numero totale di passi temporali T e definendo la **frequenza di scarica media** del neurone come $r = \frac{1}{T} \sum_{t=1}^T S(t)$ (con $r \in [0, 1]$):

$$\frac{V_j(T) - V_j(0)}{T} = \sum_i W_{ji} r_i + \frac{I_{\text{bias}}}{T} - V_{\text{th}} r_j$$

Se la finestra di osservazione T è sufficientemente lunga ($T \rightarrow \infty$), il termine residuo al primo membro tende a zero ($\frac{\Delta V}{T} \rightarrow 0$). Esplicitando la frequenza di scarica in uscita r_j :

$$r_j = \max \left(0, \frac{\sum_i W_{ji} r_i + b'_j}{V_{\text{th}}} \right)$$

Posto un fattore di scala opportuno tale per cui $V_{\text{th}} = 1$, la frequenza di scarica r_j della SNN diventa **identica** all'attivazione continua a_j^{ANN} della ReLU. La SNN calcola la stessa funzione non tramite un singolo prodotto scalare tra float, ma distribuendo la somma degli impulsi lungo T passi discreti.

ATTENZIONE: tutti i neuroni sono settati su una finestra temporale, finita questa finestra si fa la conta per convertire in numero continuo e iniziare con lo strato successivo.

La Pipeline di Conversione:

1. **Addestramento su GPU (ANN classica):** Si addestra una normale rete neurale (es. ResNet o CNN) su dati statici utilizzando solo attivazioni ReLU. È essenziale **rimuovere i termini di bias** (o vincolarli a zero) e non utilizzare batch normalization standard durante l'inferenza per evitare derive di potenziale incontrollate nei neuroni spiking.
2. **Scaling dei Pesi e Normalizzazione delle Soglie:** Questo è il passaggio critico. In una ANN, un'attivazione ReLU può assumere teoricamente un valore arbitrariamente grande (es. 14.5). In una SNN, la massima frequenza di scarica fisica è $r_{\text{max}} = 1$ (uno spike per ogni timestep discreto). Se un valore continuo supera la soglia, la SNN va in saturazione (*clipping error*), perdendo informazione; se invece i pesi sono troppo bassi, nessun neurone raggiunge la soglia (*underflow error*). I pesi o le soglie

V_{th} di ciascun layer vengono quindi riscaldati calcolando il massimo percentile di attivazione sul dataset di training:

$$W^{SNN} = W^{ANN} \cdot \frac{\lambda^{l-1}}{\lambda^l}$$

dove λ^l è il massimo valore di attivazione riscontrato nel layer l .

3. **Deployment Spiking:** I pesi riscaldati vengono caricati sull'architettura SNN. L'input continuo (es. i pixel dell'immagine) viene iniettato come corrente costante nel primo strato oppure convertito in treni di spike tramite processi di Poisson con frequenza proporzionale all'intensità del pixel.

Il Compromesso Fondamentale: Accuratezza vs. Latenza Il grande pregio della conversione è che permette di sfruttare l'ecosistema consolidato del Deep Learning: si ottengono architetture profonde con un degrado di accuratezza quasi nullo ($< 1\%$) rispetto alla controparte ANN su benchmark complessi come ImageNet.

Il costo strutturale è però la **perdita del vantaggio temporale**:

- Per rappresentare con precisione fine un'attivazione continua pari a 0.01, la SNN ha bisogno di emettere 1 spike ogni 100 intervalli di tempo. Ciò impone una finestra di simulazione T nell'ordine di centinaia o migliaia di millisecondi ($T \approx 100-1000$ ms).
- Questa enorme latenza di inferenza moltiplica il consumo energetico totale (ogni timestep richiede cicli di calcolo su silicio) e vanifica l'elaborazione a eventi istantanea (*Time-to-First-Spike*), rendendo i modelli convertiti poco competitivi per compiti reattivi in tempo reale a bordo di piattaforme robotiche autonome.

6 Le SNN nell'Embodied AI: Vantaggi e Hardware Neuromorfico

Perché investire nella complessità delle SNN quando le ANN frame-based dominano? La risposta risiede nell'efficienza operativa nel mondo reale.

- **Efficienza Energetica (Sparsità Causa-Effetto):** Nelle ANN, tutti i neuroni sono computazionalmente attivi ad ogni frame. Nelle SNN, i neuroni consumano energia **solo quando emettono uno spike**. Se la scena è statica, la rete è silente. Questa sparsità estrema, se implementata su hardware nativo, riduce il consumo energetico di ordini di grandezza.
- **Latenza Temporale e Reattività:** Le SNN processano informazioni asincrone istantaneamente. Non devono attendere l'accumulo di un "frame". Questo è critico per task di controllo robotico ad alta velocità (es. manipolazione reattiva, droni).
- **Hardware Neuromorfico:** A differenza delle GPU massivamente parallele ottimizzate per moltiplicazioni di matrici dense, i chip neuromorfici (Intel Loihi, IBM TrueNorth, SpiNNaker) sono architetture non-Von Neumann massivamente distribuite, asincrone ed event-driven, progettate specificamente per simulare l'integrazione di membrana e la comunicazione via spike con consumi minimi.

7 Conclusioni e Frontiere della Ricerca

Le Reti Neurali Spiking rappresentano un paradigma di calcolo potente e biologicamente fondato, essenziale per il futuro dell'Intelligenza Artificiale Embedded e dei sistemi autonomi a bassa potenza. Sebbene l'addestramento rimanga una sfida complessa a causa della non-differenziabilità dei meccanismi di soglia, l'emergere di tecniche basate su gradienti surrogati e la maturazione dell'hardware neuromorfico stanno chiudendo il gap prestazionale con le ANN convenzionali.

Le frontiere della ricerca attuale si concentrano sulla fusione di principi supervisionati (gradienti surrogati) con regole locali non supervisionate (STDP) per ottenere apprendimento on-chip continuo, e sullo sviluppo di codifiche temporali sempre più efficienti per sbloccare la vera promessa di latenza zero e consumo zero in assenza di eventi.