

Riassunto Dettagliato e Aggiornato:
3D Reconstruction in Robotics
Computers and Graphics 130 (2025) 104256

NECKER

Basato sul PDF originale + qualche precisazione

17 Novembre 2025

Indice

1	Tecnologie e Tecniche di Modellazione	3
1.1	Tecnologie Pilastro	3
1.2	Tecniche di Modellazione 3D	3
2	Lavori Correlati	3
2.1	Indagini Complete sulla Ricostruzione 3D	3
2.2	Revisioni Focalizzate	3
2.3	L'Approccio del Lavoro Presente	3
3	Simultaneous Localisation and Mapping (SLAM)	4
3.1	Panoramica	4
3.2	Ricostruzione in Ambienti Interni	4
3.3	SLAM Sottomarino	4
3.4	SLAM a Risorse Limitate	4
3.5	Tecniche SLAM Collaborativo	5
3.6	SLAM Multi-Camera	5
3.7	SLAM e la Visione di NeRF e Splatting	5
3.7.1	Integrazione con Gaussian Splatting (GS)	5
3.7.2	Integrazione con NeRF	6
3.8	Risultati Quantitativi SLAM	6
4	Gaussian Splatting (GS) nella Robotica	6
4.1	Panoramica	6
4.2	Applicazioni nella Robotica	6
4.3	Evoluzione del Gaussian Splatting	7
5	Ricostruzione Semantica 3D	7
5.1	Panoramica	7
5.2	Processi di Ricostruzione Semantica 3D	7
5.2.1	Etichettatura Semantica 3D	7
5.2.2	Applicazioni in Ambienti	7
6	Ricostruzione 3D Multi-View	8
6.1	Panoramica	8
6.2	Tecniche di Ricostruzione e Fusione	8
7	Ricostruzione 3D Amodale	8
7.1	Panoramica	8
7.2	Processi di Ricostruzione Amodale	8
7.2.1	Metodi di Ricostruzione	8
7.2.2	Completamento di Forma	9

8 Pianificazione del Movimento e Collisione	9
8.1 Compressione Video e Stima del Movimento	9
9 Dataset	9
10 Risultati Sperimentali e Discussione	10
10.1 Risultati SLAM	10
10.2 Risultati Gaussian Splatting	10
10.3 Risultati Ricostruzione Semantica 3D	10
10.4 Risultati Ricostruzione Amodale	10
10.5 Risultati NeRF	10
11 Conclusioni e Sfide Future	10
12 Terminologia	11
12.1 Gaussian Splatting (GS): Rappresentazione Esplicita	11
12.2 Neural Radiance Fields (NeRF)	11
12.3 Truncated Signed Distance Function (TSDF)	12
12.4 Structure from Motion (SfM)	13
13 Riferimenti	14

Sommario

Questo documento presenta un'analisi dettagliata dei progressi nel campo della ricostruzione 3D nella robotica, un dominio cruciale nella ricerca contemporanea. La capacità dei robot di interagire e comprendere l'ambiente è significativamente migliorata dall'integrazione di tecniche di ricostruzione 3D, che si ispirano all'evoluzione naturale e alla percezione umana. Vengono esplorate metodologie all'avanguardia come SLAM, NeRF, Gaussian Splatting, Ricostruzione Semantica 3D, Ricostruzione Multi-View e Ricostruzione Amodale, evidenziando i loro contributi sinergici per l'autonomia robotica in ambienti complessi e dinamici.

1 Tecnologie e Tecniche di Modellazione

1.1 Tecnologie Pilastro

Sviluppi all'avanguardia in questo campo includono i Campi di Radianza Neurali (NeRFs), che sono un metodo formidabile per catturare geometrie di scena precise e sintetizzare nuove viste con dettagli notevoli. Accanto a NeRFs, il Simultaneous Localisation and Mapping (SLAM) fornisce la mappatura e la localizzazione in tempo reale dell'ambiente, migliorando notevolmente l'autonomia dei sistemi robotici. Il **Gaussian Splatting (GS)** sta anch'esso guadagnando popolarità, spesso utilizzato con i modelli NeRF, grazie alla sua elevata velocità.

1.2 Tecniche di Modellazione 3D

Il documento discute anche l'utilità di diverse tecniche di modellazione 3D:

- **Surfels (Dischi Orientati):** Sono eccellenti per il rendering veloce di superfici complesse e dettagliate e sono vantaggiosi nel rendering in tempo reale e nell'elaborazione di nuvole di punti.
- **Modellazione Poligonale:** Utilizza vertici e bordi per formare poligoni ed è superiore nelle applicazioni che richiedono manipolazioni geometriche precise, come il CAD e l'animazione (più precisi per la renderizzazione).

2 Lavori Correlati

Il campo della ricostruzione 3D è stato oggetto di numerosi studi e sintesi che coprono diverse tecniche e applicazioni.

2.1 Indagini Complete sulla Ricostruzione 3D

Esistono indagini che coprono un'ampia gamma di metodi, classificandoli in base alle modalità di input e all'efficacia, e ne enfatizzano l'evoluzione nel tempo.

2.2 Revisioni Focalizzate

Sono disponibili anche revisioni più mirate su framework o tecnologie specifiche:

- Analisi approfondita del framework **SLAM**, che dettaglia i suoi moduli principali e le sfide affrontate dalle reti SLAM.
- Esplorazione delle sfide e delle applicazioni della tecnologia **3D LiDAR** all'interno dei sistemi SLAM.

2.3 L'Approccio del Lavoro Presente

Questo studio si distingue concentrandosi sull'integrazione di tecnologie avanzate come **NeRF** e **SLAM** all'interno dei sistemi robotici per migliorare la percezione e l'interattività. L'obiettivo è esplorare come queste tecnologie migliorino sinergicamente le capacità robotiche in ambienti dinamici.

3 Simultaneous Localisation and Mapping (SLAM)

3.1 Panoramica

SLAM è una tecnica cruciale che consente ai dispositivi di **creare una mappa 3D** mentre si **localizzano** al suo interno e calcolano le traiettorie per la navigazione autonoma. Questa tecnica è essenziale nella robotica per generare **mappe di nuvole di punti 3D sparse in tempo reale**, permettendo ai robot di adattarsi all'ambiente circostante. SLAM ha un'ampia gamma di applicazioni in ambienti subacquei, planetari e interni. Può utilizzare diversi sensori, tra cui RGB-D e LiDAR, e può elaborare i dati utilizzando lo storage su CPU o nel **cloud**.

Il Processo SLAM si Divide in 2 Fasi in un Loop Continuo:

1. **Fase di Mappatura:** si procede a creare la mappa con vari metodi come **NeRF** oppure **GS** approfonditi in questo paper.
2. **Fase di Autolocalizzazione:** si procede a autolocalizzarsi grazie alla mappa costruita per poi ripartire con il loop riaggiornando la mappa o ampliandola.

3.2 Ricostruzione in Ambienti Interni

L'integrazione delle tecniche SLAM negli ambienti interni ha portato a progressi significativi:

- **Efficienza Hardware:** Un sistema basato su **FPGA** e **CPU** può generare ricostruzioni SLAM di ambienti interni utilizzando LiDAR per creare mappe di nuvole di punti e TSDF Fusion per ricostruzioni dense. Questo approccio offre ricostruzioni di alta qualità ma richiede hardware costoso e personalizzato.
- **Edge Computing (cloud computing ma con server in prossimità e dedicati):** Utilizzato per la ricostruzione di scene in tempo reale, elaborando i dati su un potente dispositivo *edge* e fondendo le mappe nel cloud. Questo metodo, tuttavia, fatica con scene troppo *cluttered* (ingombrate).
- **Gestione di Elementi Dinamici:** Per eliminare problemi causati da oggetti dinamici (che si muovono indipendentemente dall'osservatore) negli ambienti interni, si può usare un metodo che sfrutta i residui geometrici per ricostruire basandosi solo su oggetti statici.

3.3 SLAM Sottomarino

SLAM è esteso anche agli ambienti subacquei utilizzando veicoli sottomarini senza equipaggio (UUV).

- **Integrazione Multisensore:** Sistemi come **ORB-SLAM2** vengono combinati con un odometro acustico (DVL, giroscopio) per consentire **ricostruzioni sparse** di superfici sommerse. Un approccio multi-sensore (DVL, giroscopi, altimetri) migliora la navigazione e l'accuratezza della mappatura degli AUV in ambienti sottomarini complessi.
- **Miglioramento delle Caratteristiche:** **RU-SLAM** introduce **UWNet**, un generatore specializzato che migliora l'estrazione di caratteristiche chiave in texture deboli e immagini degradate, integrato in **ORB-SLAM3** per migliorare la robustezza in scenari subacquei complessi.
- **Localizzazione Autonoma:** La mappatura della profondità combinata con la comprensione semantica migliora la localizzazione autonoma quando il GPS non è disponibile.

3.4 SLAM a Risorse Limitate

Nei dispositivi a bassa memoria, un sistema SLAM è in grado di eseguire **ricostruzioni sparse** sui robot per produrre **mappe dense basate su voxel** da dati SLAM sparsi, dimostrando efficienza per ricostruzioni su larga scala nonostante alcune limitazioni di accuratezza.

- **Sistemi Multirobot:** Un sistema multirobot può distribuire i calcoli ai dispositivi *edge* e unire le mappe nel cloud, anche se questo sistema può affrontare sfide nell'accuratezza della mappa a causa di scansioni incomplete.

- **Integrazione di Sensori:** L'integrazione di sensori LiDAR e RGB-D (**D** sta per depth) consente la ricostruzione densa 3D utilizzando un piccolo robot cingolato, dove LiDAR costruisce una mappa SLAM 2D e i dati RGB-D affinano la ricostruzione, sebbene le richieste computazionali rappresentino una sfida per le applicazioni in tempo reale.

3.5 Tecniche SLAM Collaborativo

Lo SLAM collaborativo utilizza più robot (ad esempio, un drone e un robot quadrupede terrestre) per la pianificazione congiunta della traiettoria in ambienti caotici.

- **Processo di Mappatura:** Il drone produce la **mappa di punti SLAM iniziale** (sparsa), che viene successivamente voxelizzata per mostrare l'ambiente in relazione ad entrambi i robot, facilitando la pianificazione iniziale della traiettoria per il robot quadrupede.
- **Aggiornamento della Mappa:** Il robot terrestre esegue la traiettoria inizializzata e aggiorna la traiettoria e la mappa con la telecamera RGB-D di bordo se sono presenti oggetti non visti nella scena.

3.6 SLAM Multi-Camera

I sistemi SLAM multi-camera presentano diversi vantaggi significativi rispetto ai sistemi a telecamera singola:

- **Campo Visivo Migliorato:** Le telecamere multiple catturano simultaneamente diverse prospettive, mitigando il rischio di perdere il tracciamento dei *landmark*, specialmente in ambienti dinamici o ingombrati.
- **Migliore Stima della Profondità:** Le configurazioni stereo o multi-camera ottengono intrinsecamente informazioni sulla profondità tramite triangolazione, portando a una **ricostruzione tridimensionale superiore** e a una **maggiore precisione di localizzazione**.
- **Robustezza Aumentata:** I sistemi multi-camera sono più robusti all'occlusione e più adatti a gestire ambienti dinamici, a differenza dello SLAM a telecamera singola che può incontrare sfide che possono portare a errori di localizzazione significativi.

Per i sistemi multi-camera asincroni (immagini non correlate dato che il robot potrebbe aver cambiato posizione, generalmente si fa riferimento ai sensori dello stesso robot), è necessario un sistema per allineare le immagini a un **quadro temporale continuo** incorporando un modello di movimento a tempo continuo. Per i sistemi sincroni, il concetto di **BundledFrame** (una telecamera virtuale) consente l'integrazione di misurazioni da tutte le telecamere, facilitando una fusione efficace dei dati e un'accurata stima della traiettoria (BundledSLAM).

3.7 SLAM e la Visione di NeRF e Splatting

I recenti sviluppi hanno integrato SLAM con tecniche di rendering all'avanguardia per migliorare le prestazioni.

3.7.1 Integrazione con Gaussian Splatting (GS)

GS modella una scena 3D come un campo di densità continuo composto da **primitive Gaussiane**.

- **Rendering Veloce:** GS facilita il rendering efficiente, permettendo aggiornamenti rapidi della mappa aggiungendo Gaussiane in regioni precedentemente non viste.
- **GS-SLAM:** Utilizza una strategia *coarse-to-fine* (dal grezzo al fine) per selezionare le Gaussiane 3D affidabili, ottimizzando la stima della posa della telecamera e migliorando la stabilità e l'accuratezza del *tracking*.
- **SLAM Attivo:** **AG-SLAM** è il primo sistema ad incorporare la rappresentazione 3DGS in un framework **SLAM attivo**, consentendo l'esplorazione autonoma e la mappatura di ambienti sconosciuti in tempo reale e con alta qualità.

3.7.2 Integrazione con NeRF

I sistemi SLAM tradizionali basati su NeRF si basano su un singolo Percettore Multistrato (MLP) per rappresentare l'intera scena, il che può portare a ricostruzioni eccessivamente *lisce* e sfide di scalabilità.

- **Scalabilità: NICE-SLAM** risolve queste limitazioni introducendo una **rappresentazione gerarchica basata su griglia** per aggiornamenti localizzati e una migliore scalabilità.
- **Robustezza Dinamica: RoDyn-SLAM** affronta le scene dinamiche integrando NeRF con la generazione di *motion masks* (maschere di movimento) per filtrare i raggi non validi, fusione di maschere di flusso ottico e maschere semantiche per distinguere con precisione tra elementi statici e dinamici.

3.8 Risultati Quantitativi SLAM

L'efficienza in tempo reale è una metrica chiave nello SLAM.

- **Efficienza Temporale e Energetica: SLAM-Box** (LiDAR, FPGA + CPU) raggiunge un tempo medio di scansione di **38 ms** e un consumo energetico di **13.8 W**.
- **Confronto Sensore (KITTI)**: I sistemi con telecamera stereo (es. ORB-SLAM2 e RTABMap) ottengono valori TRMSE (Translation RMSE) significativamente più bassi (circa 2.81 e 2.817) rispetto agli approcci monoculari (es. ORB-SLAM3 con 16.878), evidenziando il vantaggio dei dati stereo per la stima della traiettoria.
- **Accuratezza (TUM RGB-D)**: I metodi RGB-D superano gli approcci monoculari. **NICE-SLAM** ottiene un ATE RMSE di 2.6, significativamente migliore dei metodi monoculari.

4 Gaussian Splatting (GS) nella Robotica

4.1 Panoramica

Il Gaussian Splatting (GS) è una tecnica utilizzata per la ricostruzione 3D, il rendering e la rappresentazione dei dati (vedi sezione **Terminologia**).

4.2 Applicazioni nella Robotica

GS è applicato alla robotica per la navigazione e la manipolazione:

- **Navigazione Sicura: Splat-Plan e Splat-Loc** utilizzano mappe GSplat per la pianificazione sicura della traiettoria (attraverso corridoi politopali: calcola dalla mappa le aree considerate vuote) e la localizzazione robusta della posa (confronta la mappa che ha con ciò che vede per calcolare la trasformazione e quindi la posa, più robusta delle nuvole di punti classiche dato che riempie gli spazi vuoti). Questo approccio consente l'inizializzazione globale della posa senza conoscenze precedenti, sfruttando la natura a nuvola di punti delle scene GSplat.
- **Manipolazione Semantica**: L'integrazione semantica *object-centric* permette di inizializzare e aggiornare collettivamente le Gaussiane con etichette semantiche identiche. Le splat Gaussiane integrano i dettagli RGB con la rappresentazione geometrica, migliorando la qualità semantica e facilitando gli aggiornamenti in tempo reale.
- **SLAM: Gaussian splat SLAM** può ricostruire oggetti minuscoli e persino trasparenti, spesso difficili per le tecniche SLAM tradizionali, e ottiene risultati all'avanguardia nella sintesi di nuove viste.
- **Interazione Uomo-Robot (HRI)**: GS è più efficace di NeRF per migliorare l'HRI in contesti ad alto rischio (come i soccorsi in caso di disastro) grazie alla sua velocità di rendering superiore.

4.3 Evoluzione del Gaussian Splatting

L'evoluzione delle tecniche GS ha portato a miglioramenti nell'efficienza e nella qualità. Sviluppi recenti includono:

- **Consistenza della Vista:** L'implementazione di un meccanismo di *sorted splatting* per migliorare la stabilità durante i processi di rendering.
- **Uniformità della Superficie:** Un algoritmo di *split* focalizzato sul miglioramento dell'uniformità della superficie e dell'aderenza, che facilita l'estrazione più accurata di nuvole di punti.
- **Miglioramento del Dettaglio:** L'integrazione delle normali della superficie nel *rendering pipeline* per aumentare la stima dei dettagli della superficie (confrontandole con le normali calcolate dai sensori come LIDAR).
- **Anti-aliasing:** L'introduzione di un approccio multi-scala (renderizzo sempre più nel dettaglio solo se mi avvicino all'oggetto) per mitigare gli artefatti di *aliasing* (scalettatura dell'immagine, dovuta per esempio se il robot si muove in fretta), garantendo un rendering più fluido.

5 Ricostruzione Semantica 3D

5.1 Panoramica

La Ricostruzione/Etichettatura Semantica 3D è una tecnica utilizzata nella robotica per ricostruire ed etichettare le ricostruzioni 3D, assegnando un certo colore per distinguere gli oggetti in base alle loro proprietà semantiche. Questo aggiunge un livello di contesto informativo critico per le operazioni autonome. I metodi moderni estendono questa tecnica utilizzando il **Gaussian Splatting**, che rappresenta ogni punto in una nuvola di punti con un kernel Gaussiano per creare una superficie continua e dettagliata.

5.2 Processi di Ricostruzione Semantica 3D

5.2.1 Etichettatura Semantica 3D

L'etichettatura semantica 2D categorizza gli oggetti percepiti in un video e produce un colore per indicare il tipo di oggetto. Questa etichettatura 2D (spesso addestrata su dataset come KITTI e Semantic3D) viene applicata alle ricostruzioni di scene per mostrare le dimensioni di certi oggetti all'interno della ricostruzione.

Le ricostruzioni semantiche 3D si presentano in due forme:

- **Ricostruzioni Sparse:** Consistono tipicamente in una nuvola di punti sparsa, dove le scene etichettate 2D frame per frame sono aumentate per assegnare a ciascun punto un colore corrispondente all'oggetto che rappresenta. Queste forniscono informazioni sufficienti ai sistemi robotici per comprendere e navigare.
- **Ricostruzioni Dense:** Utilizzano metodi come algoritmi *marching cube* e mappe di punti dense per produrre mesh dettagliate. Ad esempio, i metodi di **voxelizzazione** sono usati per ricostruire la scena e proiettare i colori dalla mappa semantica sulla ricostruzione. La funzione di distanza con segno troncata (**TSDF**) è utilizzata per evidenziare le superfici con un colore specifico, consentendo a un robot di navigare e pulire superfici selezionate.

5.2.2 Applicazioni in Ambienti

- **Interni:** Si concentra sull'etichettatura di oggetti come sedie e tavoli per il riconoscimento e l'interazione da parte del robot, anche se l'elaborazione e l'etichettatura di oggetti sottili (es. gambe di sedia) possono essere problematiche.
- **Esterni e Collaborativi:** L'uso di più robot (ad esempio, un'auto e un drone) può ridurre il tempo richiesto per la **ricostruzione sparsa**. I robot possono scansionare un'area e fondere semanticamente tutte le scansioni per produrre una mappa globale. Tuttavia, alcuni metodi multi-robot producono **mappe sparse incomplete**, non adatte per ricostruzioni dense di alta qualità.

6 Ricostruzione 3D Multi-View

6.1 Panoramica

L'uso di **viste multiple** di un oggetto generalmente migliora la qualità complessiva della ricostruzione. Molti approcci utilizzano una traiettoria per produrre viste multiple dell'oggetto percepito, spesso impiegando algoritmi di **Structure from Motion (SfM)**. Altri metodi ricostruiscono oggetti da immagini prese da diverse posizioni mentre il dispositivo di acquisizione è in posizione fissa o mosso su un braccio robotico.

6.2 Tecniche di Ricostruzione e Fusione

- **Punti di Vista e Sensori:** Le scene sono catturate utilizzando telecamere **stereo** e **monoculari**. Le nuvole di punti sono favorite per un fattore di costo inferiore nelle prestazioni sui dispositivi computerizzati.
- **Triangolazione e Mappatura:** I fotogrammi della telecamera possono essere correlati e fusi tramite triangolazione o sviluppando una mappa di profondità per creare una mesh, utilizzando dati GPS per fondere le ricostruzioni.
- **Tecniche di Fusione:**
 - **Structure from Motion (SfM):** Prende viste multiple senza posizioni reciproche note e le abbina per produrre una ricostruzione. Questo metodo è utilizzato dalle telecamere monoculari perché non si basa su distanze affidabili tra le lenti.
 - **TSDF Fusion (Truncated Signed Distance Function):** Utilizza mappe di profondità multiple da viste percepite da telecamere stereo per produrre ricostruzioni di alta qualità.
 - **Amodalità da Zero: DUS3R** elimina la necessità di parametri o pose della telecamera noti regredendo (attraverso neural net) direttamente le mappe di punti 3D dalle coppie di immagini, consentendo la ricostruzione densa senza informazioni precedenti sulla telecamera.
 - **Detector-Free SfM:** Affronta le limitazioni di SfM basato su *keypoint* (difficile in scene povere di texture) eliminando la necessità di rilevamento esplicito di *keypoint* e utilizzando *matcher detector-free* per stabilire le corrispondenze (La rete impara a trovare corrispondenze geometriche tra due immagini anche in aree visivamente uniformi).

7 Ricostruzione 3D Amodale

7.1 Panoramica

La ricostruzione amodale prende la vista percepita e la ricostruisce, quindi utilizza una **Rete Neurale** per **completare l'oggetto** in relazione a un database di oggetti. L'obiettivo principale di questo metodo è migliorare la **manipolazione degli oggetti** da parte dei robot.

- **Rappresentazione:** Alcuni metodi utilizzano **nuvole di punti** (meno costose computazionalmente ma riducono la qualità), mentre altri usano la fusione di mesh TSDF (computazionalmente pesante ma accurata).
- **Realismo Fisico: ARM** utilizza *priors* (conoscienze pregresse: ad esempio riconosce la forma di un tavolo) sulle proprietà fisiche (connettività e oggetti: sa che gli oggetti solidi sono continui e non punti scollegati) per aumentare il realismo fisico delle ricostruzioni amodali.

7.2 Processi di Ricostruzione Amodale

7.2.1 Metodi di Ricostruzione

Vengono utilizzati metodi di nuvole di punti sparse e dense, modelli TSDF fusi e mappe di voxel. Si verificano due ricostruzioni: una per l'oggetto percepito (forma incompleta) e una per il completamento della forma (ricostruisce la parte incompleta).

7.2.2 Completamento di Forma

Il completamento della forma stima le parti mancanti di una ricostruzione incompleta per migliorare la manipolazione degli oggetti. Tipicamente impiega una rete neurale, addestrata su un database di oggetti (es. YCB o ShapeNet).

- **Orientamento alla Presa (Grasp):** La rete può concentrarsi sulla previsione delle posizioni di presa (grasp positions). Ad esempio, un metodo utilizza una nuvola di punti densa percepita e una stima sparsa delle parti mancanti per prevedere le posizioni di presa (non ricostruisce l'oggetto ma prevede direttamente i movimenti per afferrarlo).
- **Orientamento alla Ricostruzione:** La rete può migliorare la ricostruzione dell'oggetto per una migliore manipolazione. Ad esempio, la ricostruzione voxelizzata completata della forma di oggetti utilizza un modello TSDF percepito (non prevede i movimenti ma ricostruisce l'oggetto in maniera utile per il robot).
- **Accuratezza:** L'accuratezza può essere migliorata utilizzando database di riferimento personalizzati, come un algoritmo che utilizza un database di riferimento personalizzato di frutta e verdura ricostruite (CoRe) per migliorare la forma degli oggetti completati.

8 Pianificazione del Movimento e Collisione

NeRFs sono utilizzati per garantire percorsi senza collisioni per i robot.

- **Navigazione Vision-Only:** Si possono tracciare ed eseguire percorsi impeccabilmente senza collisioni utilizzando solo l'input della telecamera RGB.
- **Quantificazione dell'Incertezza:** Un approccio trasformativo modella i NeRF in equivalenti **Poisson Point Processes (PPPs)** per quantificare rigorosamente l'incertezza e calcolare le probabilità di collisione. Questo utilizza una rappresentazione a voxel chiamata **Probabilistic Unsafe Robot Region (PURR)** per facilitare l'ottimizzazione rapida della traiettoria.

8.1 Compressione Video e Stima del Movimento

NeRFs hanno potenziale per la compressione video e la stima del movimento in ambito industriale e robotico.

- **Stima del Movimento:** Il modello **Dynamic-NeRF (D-NeRF)** può stimare con precisione le informazioni sulla profondità e le dinamiche di movimento (ad esempio, dei bracci robotici).
- **Compressione Video:** Le tecniche basate su NeRF possono ottenere risparmi di compressione fino al 48% per video ad alta risoluzione, facilitando il trasferimento più veloce dei dati e migliorando le prestazioni in tempo reale nella robotica.

9 Dataset

I dataset sono classificati in base alle aree di applicazione (es. interazione umana, oggetti/forme, scene e semantica).

- **Ricostruzione Semantica:** Utilizza dataset come **KITTI** e **ADE20K**, noti per la loro vasta gamma di scene e oggetti etichettati semanticamente.
- **Ricostruzione Amodale/Presa:** Impiega dataset come **YCB** e **ShapeNet** per coprire una vasta gamma di oggetti, facilitando la ricostruzione completa degli oggetti per la presa accurata.
- **SLAM e Multi-View:** Dataset come **EuRoC** e **TUM-RGBD** sono ampiamente utilizzati per la ricerca SLAM e odometria visiva, fornendo verità di base accurate.
- **NeRF:** Il dataset **NeRF Synthetic** è specificamente pensato per valutare i modelli NeRF, con scene sintetiche 3D e oggetti renderizzati da diversi punti di vista.

10 Risultati Sperimentali e Discussione

10.1 Risultati SLAM

SLAM ha dimostrato un **runtime notevolmente ridotto** rispetto ad altri metodi di ricostruzione. L'uso di tecniche di **edge computing** è fondamentale per ridurre ulteriormente il tempo di esecuzione dell'algoritmo SLAM.

- **Precisione Sensore:** I sistemi stereo e RGB-D superano gli approcci monoculari in metriche come TRMSE e ATE.
- **Efficienza Collaborativa:** RecSLAM e Collaborative SLAM utilizzano tecniche di mappatura SLAM tradizionali e ricostruzione sparsa.

10.2 Risultati Gaussian Splatting

I metodi basati su Gaussian mostrano prestazioni elevate.

- **Qualità di Ricostruzione:** Nell'ambiente Replica, HF-SLAM supera gli altri metodi in ricostruzione con un PSNR di 35.74.
- **Tasso di Successo della Presa:** ManiGaussian raggiunge un tasso di successo della presa del 44.8%, mentre Splat-MOVER eccelle con un tasso di successo del 100%.

10.3 Risultati Ricostruzione Semantica 3D

I metodi di ricostruzione densa (es. RTSDM) raggiungono un IoU elevato (85.1%) con un ATE basso (0.11345 m). I metodi sparsi (es. Kimera-Multi) sono generalmente più rapidi ma possono variare in accuratezza.

10.4 Risultati Ricostruzione Amodale

L'approccio **Point Cloud Shape Completed** (kPAM-SC) mostra un miglioramento significativo nel tasso di successo della presa (96%), rispetto ai metodi Voxel/Mesh (es. ARM con 42%).

10.5 Risultati NeRF

Dex-NeRF ottiene il più alto tasso di successo nella manipolazione (96.6%). Per la navigazione, **CollisionNeRF** (83.0%) e **NeRF2Real** (78.0%) dimostrano alti tassi di successo nelle attività di navigazione.

11 Conclusioni e Sfide Future

Gli sviluppi come SLAM e NeRF hanno notevolmente potenziato le capacità robotiche nel comprendere e interagire con ambienti complessi. Tuttavia, persistono ostacoli significativi:

- **Intensità Computazionale:** La complessità computazionale e l'integrazione dei dati spesso ostacolano l'elaborazione in tempo reale.
- **Dataset Limitati:** La mancanza di dataset diversi e completi che rappresentino la varietà degli scenari che i robot potrebbero incontrare è una limitazione significativa.
- **Gestione dell'Occlusione:** I metodi attuali faticano ad affrontare con precisione le **occlusioni** e le **viste parziali**.
- **Integrazione Sensore:** Mancanza di integrazione tra gli algoritmi di ricostruzione 3D e le tecnologie avanzate dei sensori, come l'imaging termico.

La ricerca futura dovrebbe concentrarsi sull'integrazione dell'IA per migliorare la comprensione semantica e lo sviluppo di algoritmi che ottimizzino l'efficienza computazionale. L'esplorazione di metodi di apprendimento non supervisionato potrebbe anche consentire ai robot di adattarsi in modo più efficiente a nuovi ambienti.

12 Terminologia

12.1 Gaussian Splatting (GS): Rappresentazione Esplicita

Il **Gaussian Splatting (GS)** è una tecnica di ricostruzione 3D e rendering che modella esplicitamente una scena come una collezione di **milioni di primitive elementari**: i **kernel Gaussiani 3D**. Questo approccio esplicito offre notevoli vantaggi in termini di velocità rispetto ai metodi impliciti come NeRF.

1. Il Kernel Gaussiano 3D

In GS, un singolo Gaussiano non è una curva statistica, ma una **forma 3D ellissoidale e sfocata** i cui parametri sono ottimizzati per rappresentare un piccolo frammento di materia nello spazio. Ogni Gaussiano i è definito da un set di parametri espliciti:

- **Posizione Centrale (μ_i)**: Le coordinate (x, y, z) del centro.
- **Covarianza (Σ_i)**: Una matrice che definisce la **forma** (scala sui tre assi) e l'**orientamento** del kernel 3D.
- **Colore e Opacità**: Colore (c_i) e opacità (α_i).

2. Addestramento come Ottimizzazione Differenziabile

L'addestramento non ottimizza i pesi di una rete MLP (come NeRF), ma ottimizza i **parametri espliciti di ogni singolo Gaussiano**.

1. **Inizializzazione**: L'addestramento inizia con una **nuvola di punti 3D sparsa** (generata da SfM), dove ogni punto fornisce la posizione iniziale (μ) per un Gaussiano.
2. **Ottimizzazione**: Il processo utilizza la **Retropropagazione** per calcolare il gradiente della *Loss Function* (errore di colore) rispetto a tutti i parametri di tutti i Gaussiani. Questo permette al sistema di "fittare" e scolpire la forma e la posizione di ogni ellissoide finché la loro combinazione non riproduce perfettamente le immagini 2D di addestramento.

3. Efficienza di Rendering (Splatting)

La velocità di GS deriva dal suo metodo di rendering, lo **Splatting**, che è molto più efficiente del *Volume Rendering* basato su raggi di NeRF:

- **Conversione 3D $\rightarrow$ 2D**: I Gaussiani 3D sono direttamente **proiettati** sullo schermo come kernel Gaussiani 2D (ellissi), cercando di far fittare queste ellissi ai punti della nuvola.
- **Rasterizzazione Accelerata**: Queste ellissi 2D vengono ordinate per profondità (*Z-sorting*) e accumulate (fuse) per produrre il colore finale del pixel. Poiché si basa principalmente sull'elaborazione geometrica e sull'accumulo, il processo sfrutta l'accelerazione **Hardware delle GPU** (simile alla rasterizzazione della grafica tradizionale), riducendo i tempi di rendering da secondi a **millisecondi** (rendimento in tempo reale).

In sintesi, GS sacrifica la rappresentazione implicita continua di NeRF in favore di una rappresentazione esplicita e manipolabile che permette un rendering estremamente rapido.

12.2 Neural Radiance Fields (NeRF)

I **Neural Radiance Fields (NeRF)** sono una tecnica di *novel view synthesis* (sintesi di nuove viste) che utilizza una rete neurale per rappresentare una scena 3D in modo implicito e continuo.

1. La Rappresentazione 5D Implicita

A differenza delle rappresentazioni esplicite (come mesh o nuvole di punti), NeRF modella la scena come una funzione continua $\mathcal{F}$ codificata nei pesi di una **rete neurale *Fully Connected* (MLP)**.

L'input della funzione è un vettore a 5 dimensioni, e l'output è una coppia di valori:

$$\mathcal{F} : (\mathbf{x}, \mathbf{d}) \rightarrow (\mathbf{c}, \sigma)$$

Dove:

- $\mathbf{x} = (x, y, z) \in \mathbb{R}^3$: **Posizione 3D** nello spazio.
- $\mathbf{d} = (\theta, \phi) \in \mathbb{R}^2$: **Direzione di Visualizzazione** (viewing direction).
- $\mathbf{c} \in \mathbb{R}^3$: **Colore RGB** emesso in $\mathbf{x}$ se visto dalla direzione $\mathbf{d}$.
- $\sigma \in \mathbb{R}$: **Densità Volumetrica** (o opacità differenziale) in $\mathbf{x}$.

Per catturare dettagli ad alta frequenza (texture), le coordinate $\mathbf{x}$ e $\mathbf{d}$ sono prima mappate in uno spazio ad alta dimensione tramite una **Codifica Posizionale** (*Positional Encoding*).

2. Il Volume Rendering

La sintesi di una vista da una telecamera virtuale è ottenuta tramite **Volume Rendering**. Per ogni pixel di un'immagine da rendere, viene lanciato un raggio luminoso r attraverso la scena e si campionano tra i 100-200 punti sul raggio. Il colore finale $\mathbf{C}(r)$ del pixel è calcolato integrando i valori di colore e densità dei punti predetti dalla rete lungo il raggio:

$$\mathbf{C}(r) = \int_{t_n}^{t_f} T(t) \cdot \sigma(\mathbf{r}(t)) \cdot \mathbf{c}(\mathbf{r}(t), \mathbf{d}) dt$$

Dove $T(t)$ è la funzione di **Trasmissione** (la probabilità che la luce raggiunga il punto t senza essere occlusa) e $\mathbf{r}(t)$ è il punto 3D sul raggio.

3. Addestramento e Funzione di Perdita

NeRF è addestrato su un set di immagini 2D con pose della telecamera note. L'addestramento è un processo di **overfitting** sulla scena specifica.

La rete viene ottimizzata per minimizzare la **Loss Function** ($\mathcal{L}$), tipicamente l'Errore Quadratico Medio (L_2 Loss), tra il colore predetto (renderizzato) e il colore reale del pixel:

$$\mathcal{L} = \sum_r \|\mathbf{C}_{predetto}(r) - \mathbf{C}_{reale}(r)\|^2$$

L'errore viene retro-propagato attraverso il processo di Volume Rendering per aggiornare i pesi della rete tramite **Discesa del Gradiente**, costringendo la rete a codificare la geometria e l'illuminazione corrette della scena.

4. Vincolo di Ristrutturazione

Un aspetto cruciale di NeRF è che è un modello **specifico per scena**. Se si cambia la scena (e.g., da un ufficio a un giardino), è necessario **riaddestrare completamente la rete** sui nuovi dati.

12.3 Truncated Signed Distance Function (TSDF)

La **TSDF (Truncated Signed Distance Function)** è una rappresentazione geometrica volumetrica ampiamente utilizzata nello SLAM in tempo reale (e.g., KinectFusion) per ricostruire scene 3D dense a partire da sensori di profondità.

1. La Rappresentazione Volumetrica

TSDF modella la scena come una griglia 3D di cubetti discreti chiamati **voxel**. Ogni voxel v memorizza due valori principali:

- **Valore TSDF**: La distanza del voxel dalla superficie più vicina.
- **Peso (W)**: L'affidabilità o il numero di misurazioni che hanno contribuito a questo valore.

2. La Funzione di Distanza con Segno (SDF)

Il valore TSDF codifica la relazione del voxel con la superficie:

- **Positivo (> 0):** Il voxel si trova nello **spazio libero** (tra il sensore e la superficie misurata).
- **Negativo (< 0):** Il voxel si trova nello **spazio occupato** (l'interno dell'oggetto, per presunzione di solidità).
- **Zero ($= 0$):** Il voxel si trova **sulla superficie**.

La **Troncatura** (τ) limita il calcolo e la memorizzazione ai soli voxel che si trovano entro una piccola banda di distanza ($\pm\tau$) dalla superficie, migliorando l'efficienza.

3. Identificazione della Superficie tramite Fusione

La superficie non è identificata da una singola misurazione rumorosa, ma dalla ****convergenza statistica**** di misurazioni multiple:

- **Fusione Ponderata:** Quando un nuovo raggio di profondità viene acquisito, aggiorna una colonna di voxel attorno al punto di impatto. Il nuovo valore TSDF è calcolato tramite una **media ponderata** tra il vecchio valore e la nuova stima, che smorza il rumore del sensore.

$$D_{fusione} = \frac{W_{vecchio} \cdot D_{vecchio} + W_{nuovo} \cdot D_{nuovo}}{W_{vecchio} + W_{nuovo}}$$

- **Zero-Crossing:** La superficie 3D finale (estratta tramite *Marching Cubes*) è definita dal luogo geometrico di tutti i voxel che hanno un valore **TSDF pari a zero**. Questo 0 rappresenta la posizione statistica più affidabile tra lo spazio positivo (esterno) e lo spazio negativo (interno).

12.4 Structure from Motion (SfM)

Structure from Motion (SfM) è una tecnica di visione artificiale che ricostruisce la geometria 3D di una scena (*Structure*) e stima la posizione e l'orientamento di tutte le telecamere (*Motion*) a partire da un insieme non ordinato di immagini 2D. È il precursore essenziale per la ricostruzione densa (come NeRF o GSplat).

1. Fasi del Processo SfM

Il processo si basa sulla ricerca di corrispondenze geometriche e sull'ottimizzazione:

1. **Feature Detection e Matching:** Si identificano i **punti chiave** (*keypoint*) distintivi in ogni immagine (tramite algoritmi come SIFT o ORB) e si stabiliscono le **corrispondenze** tra le diverse viste.
2. **Triangolazione:** Utilizzando le corrispondenze 2D e la posa stimata delle telecamere, si calcola la posizione 3D dei punti chiave nello spazio (vedi sotto).
3. **Stima Iniziale della Posa:** Si risolve il problema delle **Matrici Essenziale e Fondamentale** per stimare la posizione e l'orientamento relativi delle telecamere. Questo fornisce l'input cruciale per la triangolazione.
4. **Bundle Adjustment (Ottimizzazione Globale):** È l'ultima fase di raffinamento. È una tecnica di ottimizzazione che minimizza l'errore di **riproiezione** (la differenza tra dove un punto 3D viene proiettato sull'immagine e dove è stato effettivamente rilevato come *keypoint*). Il BA ottimizza contemporaneamente tutte le pose delle telecamere e tutte le posizioni dei punti 3D per ottenere la massima coerenza geometrica.

2. Il Meccanismo della Triangolazione

La triangolazione è il cuore del calcolo 3D. Non richiede la lunghezza del raggio in input, ma la calcola come output.

- **Input:** La **posa 3D** nota di almeno due telecamere (la loro posizione e orientamento $R|t$) e le coordinate 2D di un punto corrispondente su entrambe le immagini.
- **Principio:** Per ogni punto 2D su un'immagine, si può definire un **raggio proiettivo** che parte dal centro ottico della telecamera.
- **Output:** La posizione 3D reale del punto nella scena (P) è data dall'**intersezione** di due o più raggi proiettivi. Poiché nel mondo reale i raggi non si intersecano perfettamente a causa del rumore, la triangolazione calcola la coordinata 3D $P = (X, Y, Z)$ che **minimizza la distanza** tra i due raggi nello spazio, risolvendo così l'incertezza sulla **profondità** (lunghezza del raggio).

13 Riferimenti

Riferimenti bibliografici

- [1] Selvaratnam, D., Bazazian, D. (2025).
3D Reconstruction in Robotics: A Comprehensive Review.
Computers & Graphics, 130, 104256.
<https://doi.org/10.1016/j.cag.2025.104256>