

Fondamenti Matematici e Interpretazione Pratica dell'Inferenza Statistica: Dai Test sulle Medie ai Modelli Predittivi Lineari

NECKER

3 Giugno 2026

Indice

1	La Verifica di Ipotesi: Il Processo Decisionale	2
1.1	Le Ipotesi e il Livello di Significatività (α)	2
1.2	Statistica Test e p-value	2
1.3	Esempio Applicativo: Verifica del contenuto medio	3
2	La Scelta della Distribuzione: Normale Standard (Z) vs. t di Student	4
2.1	Il Problema dell'Incertezza Aggiuntiva	4
2.2	Differenze Geometriche e Teoriche	5
2.3	Come e Quando Usarle	5
3	Quando usare α intero vs. $\alpha/2$	6
3.1	Usare α intero: I Test a Una Coda (Unilaterali)	6
3.2	Usare $\alpha/2$: I Test a Due Code e gli Intervalli (Bilaterali)	6
4	Regressione Lineare Semplice	7
4.1	I Coefficienti del Modello (β_0 e β_1)	7
4.2	La Bontà di Adattamento: Il Coefficiente di Determinazione (R^2)	7
4.3	L'Incertezza: Intervalli di Confidenza vs. Previsione	8
4.4	Esempio Applicativo: Resa Agricola (Fertilizzante e Pomodori)	9

1 La Verifica di Ipotesi: Il Processo Decisionale

La verifica di ipotesi è una procedura statistica che permette di prendere decisioni sulla popolazione a partire dalle informazioni fornite da un campione. La logica di base è assimilabile a quella di un processo in tribunale, dove vale il principio di presunzione di innocenza.

1.1 Le Ipotesi e il Livello di Significatività (α)

Il test si imposta contrapponendo due ipotesi:

- **Ipotesi Nulla (H_0):** Rappresenta lo status quo, la presunzione di innocenza. Solitamente indica assenza di effetto, uguaglianza o il mantenimento di uno standard dichiarato.
- **Ipotesi Alternativa (H_1):** Rappresenta l'affermazione che si vuole dimostrare (l'accusa).

Il livello di significatività, indicato con α (Alpha), **non è una tolleranza fisica** o industriale (es. uno scarto in grammi), bensì una tolleranza sul *rischio di prendere una decisione sbagliata*. Nello specifico, α è la probabilità massima tollerata di commettere un **Errore di I specie** (falso positivo): rifiutare H_0 quando questa è in realtà vera. Fissare $\alpha = 0.05$ (5%) per esempio, significa accettare al massimo un 5% di probabilità di condannare ingiustamente un'ipotesi nulla innocente a causa di un campione sfortunato.

1.2 Statistica Test e p-value

Una volta raccolti i dati, si calcola una **Statistica Test** (es. Z o t). Questa converte i dati grezzi in una distanza standardizzata dall'ipotesi nulla.

Il **p-value** è la probabilità, calcolata supponendo H_0 vera, di ottenere un risultato uguale o più estremo di quello osservato. È il rischio reale di falso allarme insito nei dati.

- Se **p-value** $< \alpha$: L'evento è troppo raro per essere frutto del caso. Si rifiuta H_0 .
- Se **p-value** $\geq \alpha$: Non ci sono prove sufficienti (oltre il ragionevole dubbio) per rifiutare H_0 .

Approfondimento: Trovare il Valore Critico Z

Il Valore Critico è la traduzione di α sull'asse delle ascisse della distribuzione standardizzata. Definisce il confine della regione di rifiuto. Senza calcolatrici avanzate, per un test a una coda con $\alpha = 0.05$, si cercano all'interno delle tavole della distribuzione normale i valori di probabilità più vicini a 0.0500. Poiché il valore si trova esattamente a metà tra 0.0505 ($Z = -1.64$) e 0.0495 ($Z = -1.65$), per interpolazione si ottiene il valore critico di **-1.645** .

ATTENZIONE: la gaussiana rappresenta la situazione ideale, quindi se **p-value** $< \alpha$, significa che ci troviamo in una zona molto improbabile e che l'ipotesi H_0 non rispecchia fedelmente la popolazione totale.




Figura 1: Rappresentazione della regione di rifiuto (coda sinistra) per $\alpha = 0.05$.

1.3 Esempio Applicativo: Verifica del contenuto medio

Un produttore dichiara $\mu = 500\text{g}$. Si estrae un campione di $n = 36$, con media campionaria $\bar{x} = 495\text{g}$. Deviazione standard nota $\sigma = 12\text{g}$ (della popolazione totale, trovata stimandola). **Vogliamo verificare se la probabilità di estrarre una scatola 495g o inferiore se davvero la media sia 500g a scatola è inferiore alla probabilità massima accettata ($\alpha = 0.05$).**

- $H_0 : \mu = 500$ contro $H_1 : \mu < 500$
- Statistica Test: $Z = \frac{495-500}{12/\sqrt{36}} = -2.5$
- Valore Critico $Z_\alpha = -1.645$
- **Conclusione:** Poiché $Z = -2.5$ cade nella regione di rifiuto (oltre -1.645), si rifiuta H_0 . Il p-value associato è 0.0062 (0.62%), strettamente inferiore al 5%.

2 La Scelta della Distribuzione: Normale Standard (Z) vs. t di Student

utilizzare la distribuzione **Normale Standard (Z)** o la distribuzione **t di Student**? La scelta non è arbitraria, ma dipende strettamente dalle informazioni a nostra disposizione sulla popolazione e dalla dimensione del campione.

2.1 Il Problema dell'Incertezza Aggiuntiva

La distribuzione Normale Standard è il modello "perfetto". Si utilizza quando conosciamo esattamente la variabilità dell'intera popolazione, ovvero la sua deviazione standard (σ).

Tuttavia, nella realtà empirica, quasi mai conosciamo la varianza dell'intera popolazione. Se stiamo misurando il peso di un campione di confezioni, conosciamo la deviazione standard *del nostro campione* (s), non quella di tutte le confezioni mai prodotte (σ). Sostituire σ con s introduce un **nuovo livello di incertezza**: non solo la nostra media campionaria potrebbe essere imprecisa, ma ora anche la nostra stima dell'errore potrebbe esserlo.

È qui che entra in gioco la distribuzione **t di Student** (pseudonimo dello statistico William Sealy Gosset). La distribuzione t è matematicamente progettata per "assorbire" questa incertezza aggiuntiva.

2.2 Differenze Geometriche e Teoriche

Sia la curva Normale (Gaussiana) che la curva t di Student condividono alcune proprietà fondamentali:

- Sono entrambe a forma di campana (campanulari).
- Sono entrambe simmetriche rispetto allo zero (media = moda = mediana = 0).

Le differenze cruciali risiedono nella **forma delle code**:

- **Le code della t di Student sono "più pesanti" (più spesse):** Poiché c'è più incertezza (dovuta all'uso di s al posto di σ), la probabilità di ottenere valori estremi o lontani dalla media è maggiore rispetto a una distribuzione Normale perfetta. Di conseguenza, i valori critici della t sono numericamente più grandi di quelli della Z a parità di livello α , rendendo i test più "prudenti" e gli intervalli di confidenza più larghi.
- **Dipendenza dai Gradi di Libertà (df):** A differenza della Normale Standard, che è una sola curva fissa, la t di Student è in realtà una *famiglia di curve*. La forma esatta dipende dai Gradi di Libertà ($df = n - 1$). Più il campione è grande (e quindi più la dev standard del campione diventa una stima affidabile di σ), più i gradi di libertà aumentano.
- **Convergenza:** Per la Legge dei Grandi Numeri, man mano che $n \rightarrow \infty$ (convenzionalmente per $n > 30$), la curva t di Student si assottiglia e diventa praticamente indistinguibile dalla distribuzione Normale Standard.




Figura 2: Confronto tra la distribuzione Normale e la t di Student. Si noti come le curve t abbiano un picco più basso e code più "spesse", implicando una maggiore probabilità di valori estremi dovuti all'incertezza campionaria. All'aumentare dei gradi di libertà, la curva verde si avvicina alla blu.

2.3 Come e Quando Usarle

La procedura di calcolo è identica per entrambe: si calcola una statistica test e la si confronta con un valore critico (oppure si calcola il p-value). Cambiano solo la tabella di riferimento e la lettera usata per la formula.

Passaggi operativi per usare la t di Student:

1. **Verifica del requisito:** Assicurati che σ sia **ignoto** e che tu stia usando la deviazione standard del campione (s).
2. **Calcolo dei gradi di libertà:** Per un test sulla media di un singolo campione, $df = n - 1$.
ATTENZIONE: quell'uno può diventare un numero più alto a seconda del numero di incognite da stimare ES: parametri di una retta $x = mx + q$ (2)
3. **Statistica Test:** Sostituisci σ con s . La formula diventa:

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

4. **Tavole Statistiche:** Entra nelle tavole della t di Student incrociando i gradi di libertà appena calcolati (df) con il livello di significatività desiderato (es. $\alpha = 0.05$).

Matrice Decisionale

Per evitare confusioni all'esame, ecco la regola decisionale classica semplificata:

Condizioni	Campione Piccolo ($n \leq 30$)	Campione Grande ($n > 30$)
σ della popolazione NOTO	Normale (Z)	Normale (Z)
σ IGNOTO (si usa s)	t di Student	<i>Formalmente</i> t (Spesso si approssima a Z)

3 Quando usare α intero vs. $\alpha/2$

3.1 Usare α intero: I Test a Una Coda (Unilaterali)


Si utilizza tutto l'errore α (es. il 5%) concentrato su un solo lato della distribuzione (solo coda destra o solo coda sinistra) quando l'Ipotesi Alternativa (H_1) ha una direzione ben precisa.

- **Parole chiave nel testo:** "Maggiore di", "Minore di", "Migliorato", "Inferiore".
- **Logica e Applicazione:** Nel nostro primo esercizio, il sospetto era che il peso fosse *inferiore* a 500g. Non ci interessava affatto se le confezioni pesassero di più per sbaglio (quello sarebbe un danno per l'azienda, non per noi consumatori!). Poiché ci interessa solo una direzione, concentriamo tutta la nostra "potenza d'indagine" (il 5% di rischio accettato) sulla coda sinistra.

3.2 Usare $\alpha/2$: I Test a Due Code e gli Intervalli (Bilaterali)

Si divide l'errore esattamente a metà ($\alpha/2$ a destra e $\alpha/2$ a sinistra) in due situazioni fondamentali della statistica inferenziale:

- **Test di Ipotesi Bilaterali:** Quando ci interessa scoprire una qualsiasi differenza, in qualunque direzione. (Parole chiave: "Diverso da", "Cambiato", "Ha un effetto"). In questo caso, l'ipotesi alternativa H_1 usa il simbolo $\neq$. Poiché l'anomalia potrebbe presentarsi sia per eccesso che per difetto, dobbiamo dividerci le spalle equamente (es. 2.5% di rischio a destra e 2.5% a sinistra).



4 Regressione Lineare Semplice

Mentre i test d'ipotesi valutano affermazioni, la regressione lineare semplice ha l'obiettivo di modellare matematicamente la relazione tra una variabile indipendente (X , esplicativa) e una variabile dipendente (Y , risposta), per capirne l'impatto e per fare previsioni. L'equazione teorica è $\hat{Y} = \beta_0 + \beta_1 X$.

4.1 I Coefficienti del Modello (β_0 e β_1)

L'obiettivo è tracciare la retta che minimizza la distanza dai dati reali.

- **Coefficiente Angolare (β_1):** Si calcola come rapporto tra la covarianza delle due variabili e la devianza della variabile indipendente (SS_{XY}/SS_{XX}). *Interpretazione pratica:* Indica la variazione media attesa della Y per ogni incremento unitario della X .

- **Intercetta (β_0):** Si calcola forzando la retta a passare per il baricentro dei dati $(\bar{X}, \bar{Y})$. La formula inversa è $\beta_0 = \bar{Y} - \beta_1 \bar{X}$. *Interpretazione pratica:* È il valore teorico atteso della Y quando $X = 0$.

4.2 La Bontà di Adattamento: Il Coefficiente di Determinazione (R^2)

L' R^2 è la "pagella" del modello, un valore compreso tra 0 e 1 (o 0% e 100%). Esso quantifica la proporzione di varianza della variabile dipendente Y che viene spiegata dal modello lineare attraverso la variabile X . Un R^2 molto alto (es. > 0.90) indica che i dati si allineano quasi perfettamente sulla retta.

L' R^2 **corretto (o aggiustato)** inserisce una penalità dipendente dal numero di variabili indipendenti inserite, prevenendo l'illusione statistica che un modello migliori semplicemente aggiungendo variabili inutili a caso.

Approfondimento: I Gradi di Libertà ($n - k - 1$)

Nella statistica, i gradi di libertà rappresentano il "budget di informazioni indipendenti" a disposizione. Per ogni parametro che deve essere obbligatoriamente stimato dai dati prima di poter calcolare l'errore del modello, si introduce un vincolo matematico e si perde un grado di libertà.

- In un test su una singola media, si stima 1 parametro ($\bar{x}$), quindi $df = n - 1$.
- Nella regressione semplice, per tracciare la retta bisogna stimare 2 parametri (β_0 e β_1), per cui l'errore sui residui si calcola con $df = n - 2$.

4.3 L'Incertezza: Intervalli di Confidenza vs. Previsione

Calcolati i coefficienti, bisogna valutare quanto ci si possa fidare del modello stimato rispetto alla vera e ignota popolazione totale. Per farlo, si abbandona la singola stima (che è per natura quasi certamente imprecisa) e si costruisce un "recinto logico" di sicurezza. Tutti gli intervalli seguono la medesima struttura universale: **Stima Puntuale $\pm$ (Valore Critico $t \times$ Errore Standard)**.

Esistono due tipi fondamentali di intervalli applicati al modello di regressione:

1. **Intervallo di Confidenza per la pendenza (β_1):** Valuta l'incertezza strutturale del modello, ovvero l'effetto globale della X sulla Y .
 - *Il significato profondo:* Noi abbiamo calcolato una pendenza basandoci su un singolo e limitato campione di n dati. Se potessimo ripetere l'esperimento infinite volte, estraendo infiniti campioni diversi, otterremmo rette sempre leggermente diverse. Questo intervallo ci indica che siamo confidenti (es. al 95%) che la "vera" e invisibile pendenza universale della popolazione cada all'interno di questi limiti. Soprattutto, se l'intervallo *non* include lo zero, significa che l'effetto della variabile X è reale, garantendone la significatività statistica.
 - *Come si calcola:* Si utilizza l'errore standard della pendenza $SE(\beta_1)$, che dipende da quanto i punti sono dispersi attorno alla retta (l'errore dei residui s_e) e da quanto è ampia la varianza della X (SS_{XX}). La formula è:

$$\beta_1 \pm \left(t_{\alpha/2} \times \frac{s_e}{\sqrt{SS_{XX}}} \right)$$

2. **Intervallo di Previsione (Prediction Interval):** Utilizzato quando si vuole stimare non l'effetto medio, ma il valore esatto della Y per un *singolo e specifico evento futuro* dato un certo valore X_0 .

- *Il significato profondo:* Prevedere l'esito di un singolo evento è intrinsecamente più difficile e incerto che prevedere una media globale (ad esempio, una singola settimana agricola può subire una grandinata imprevista). Per questo motivo, il "recinto" della previsione deve essere matematicamente più largo per assorbire l'elevata incertezza naturale del singolo caso contingente.
- *Come si calcola:* All'interno dell'errore standard della previsione (SE_{prev}), si aggiunge un fattore di dispersione extra (il "+1" sotto la radice quadrata). La formula completa è:

$$\hat{Y}_0 \pm \left(t_{\alpha/2} \times s_e \sqrt{1 + \frac{1}{n} + \frac{(X_0 - \bar{X})^2}{SS_{XX}}} \right)$$

Nota cruciale: La presenza del termine $(X_0 - \bar{X})^2$ sotto radice indica che l'errore cresce man mano che il valore X_0 scelto si allontana dalla media $\bar{X}$. Matematicamente, questo significa che il modello è molto sicuro quando fa previsioni vicino al baricentro dei dati passati, ma diventa sempre più incerto (e l'intervallo si allarga a imbuto) se proviamo a usarlo per valori di X estremi o mai osservati.




Figura 3: Modello lineare con dispersione dei dati reali e bande di previsione per un evento singolo. Si noti come le bande tratteggiate si allarghino leggermente allontanandosi dal centro dei dati.

4.4 Esempio Applicativo: Resa Agricola (Fertilizzante e Pomodori)

Dati aggregati per $n = 10$ settimane ($\mathbf{X}$ indicano i kg di fertilizzante usato, $\mathbf{Y}$ indicano i kg di pomodori prodotti):

$$SS_{XX} = 82.5, SS_{YY} = 88.4, SS_{XY} = 83.$$

$$\text{Medie: } \bar{X} = 5.5, \bar{Y} = 6.6.$$

- **Calcolo dei Coefficienti:**

Applicando le formule teoriche per la pendenza (β_1) e l'intercetta (β_0):

$$\beta_1 = \frac{SS_{XY}}{SS_{XX}} = \frac{83}{82.5} \approx 1.006$$

$$\beta_0 = \bar{Y} - \beta_1 \bar{X} = 6.6 - (1.006 \times 5.5) \approx 1.067$$

Il modello stimato è quindi: $\hat{Y} = 1.067 + 1.006X$.

- **Previsione Singola per un nuovo valore $X_0 = 6$ kg:**

Innanzitutto calcoliamo la **stima puntuale** inserendo il valore nel modello:

$$\hat{Y} = \beta_0 + \beta_1 X_0 = 1.067 + 1.006(6) \approx 7.103 \text{ kg/m}^2$$

A causa della variabilità del singolo evento (es. condizioni meteo di quella specifica settimana), la stima puntuale non basta e dobbiamo costruire un **Intervallo di Previsione al 95%**.

Calcoliamo prima la Somma dei Quadrati degli Errori (SSE) e l'errore standard dei residui (s_e):

$$SSE = SS_{YY} - \beta_1 SS_{XY} = 88.4 - (1.006 \times 83) \approx 4.897$$

$$s_e = \sqrt{\frac{SSE}{n-2}} = \sqrt{\frac{4.897}{8}} \approx 0.782$$

Ora calcoliamo l'errore standard maggiorato per la previsione di un singolo evento (SE_{prev}):

$$SE_{prev} = s_e \sqrt{1 + \frac{1}{n} + \frac{(X_0 - \bar{X})^2}{SS_{XX}}}$$

$$SE_{prev} = 0.782 \sqrt{1 + \frac{1}{10} + \frac{(6 - 5.5)^2}{82.5}} \approx 0.822$$

Infine, sapendo che il valore critico t di Student per un test a due code con $\alpha = 0.05$ e $df = 8$ è 2.306, assembliamo l'intervallo:

$$\hat{Y} \pm (t_{\alpha/2} \times SE_{prev})$$

$$7.103 \pm (2.306 \times 0.822) \implies 7.103 \pm 1.895$$

Si ottiene un intervallo di previsione [5.208, 8.998]. Siamo certi al 95% che, in quella singola settimana, la resa agricola cadrà all'interno di questo range.

ATTENZIONE: il 95% di affidabilità significa che dobbiamo allargare i bound del coeff. angolare abbastanza da avere la prob del 95% di cadere su una retta che ha un coeff. nel bound stabilito