

Riassunto dettagliato del paper “GR00T N1: An Open Foundation Model for Generalist Humanoid Robots”

NECKER

12 Settembre 2025

Abstract

Il paper presenta GR00T N1, un modello foundation aperto per robot umanoidi generalisti. Si propone di fornire una “mente” robotica capace di ragionamento visivo-linguistico e generazione di azioni motorie fluide, su più piattaforme robotiche. Il modello è del tipo Vision-Language-Action (VLA) con una architettura “dual-system”. Viene addestrato su una grande varietà di dati (video umani, simulazioni, traiettorie reali) organizzati secondo una “piramide dei dati”. I risultati mostrano che GR00T N1 supera i metodi di apprendimento per imitazione su diversi benchmark di simulazione e dimostra efficacia su robot reale.

1. Introduzione

I robot generalisti devono combinare tre ingredienti: (1) hardware versatile, (2) modelli generali capaci di affrontare molteplici compiti, (3) strategia dati efficace. Il lavoro prende ispirazione dai “foundation models” dell’IA e mira ad applicare tale paradigma alla robotica, superando il problema dei “data-islands” (esempi di esecuzione o robot troppo diversi tra loro). Viene dunque proposto GR00T N1: modello VLA con architettura dual-system che supporta diversi embodiment e addestrato end-to-end.

2. Il modello GR00T N1

2.1 Architettura del modello

Il modello è strutturato in due sistemi interconnessi:

- **System 2 (Vision-Language):** elabora l’osservazione visiva e l’istruzione linguistica. Utilizza un Vision-Language Model (VLM) pre-addestrato (Eagle-2) per codificare immagine e testo in token condivisi. (lavora a 10hz, questo perche serve a comprendere lo scopo dell’azione e il goal e non serve farlo troppo frequentemente)
- **System 1 (Action):** un Diffusion Transformer (DiT) che genera azioni motorie ad alta frequenza condizionate dai token del modulo 2 e dallo stato del robot. (lavora a 120hz questo perche deve dire spessissimo dove il robot deve andare e che movimenti fare)

Per gestire diversi embodiment, il modello include encoder MLP specifici per embodiment che proiettano stato e azione in uno spazio embedding comune. Dato uno stato robotico s_t , osservazioni o_t , e istruzione L , il modulo Vision-Language produce embedding $z = \text{VLM}(o_t, L)$ (questo significa che dato che i robot possono essere molto diversi, il modello non predice direttamente azioni ma predice uno spazio vettoriale comune a tutti e non specializzato). Lo stato viene codificato $e_s = \text{MLP}_s(s_t)$. L’azione è generata dal DiT che prende input rumoroso e condizione (z, e_s) , imparando il campo di denoising tramite flow matching (quindi dall’embedding

generale e rumoroso estrae l'azione imparando a fare denoising). La perdita di training segue la formula di flow-matching (eq. 1 del paper).

2.2 Generazione dati e piramide dei dati

I dati sono organizzati secondo una piramide (dalla base alla punta dai dati più frequenti a quelli meno frequenti):

- **Base:** video di esseri umani egocentrici e web-scale, senza azioni esplicite.
- **Strato medio:** simulazioni robotiche e traiettorie sintetiche.
- **Apice:** dati reali da robot fisici (teleoperazione).

Per sfruttare video senza azione:

- **Latent-action codebook** (VQ-VAE) per rappresentare azioni latenti.
- **Inverse Dynamics Model** (IDM) per generare pseudo-azioni.

2.3 Addestramento

Addestramento in due fasi: pre-training (mix di dati dalla piramide) e post-training (adattamento su task specifici). Anche con pochi esempi il modello pre-addestrato mantiene buone prestazioni.

3. Risultati sperimentali

3.1 Simulazione

Valutato su:

- RoboCasa (24 task)
- DexMimicGen (9 task bimanuali)
- GR-1 Humanoid (24 task)

Metodo	RoboCasa	DexMimicGen	GR-1
BC Transformer	26.3%	53.9%	16.1%
Diffusion Policy	25.6%	56.1%	32.7%
GR00T-N1-2B	32.1%	66.5%	50.0%

3.2 Robot reale

Su GR-1 umanoide reale: successo medio 76.8 %. Con 10 % dei dati: GR00T N1 ottiene 42.6 % vs 10.2 % del baseline.

3.3 Limiti

Azioni limitate a compiti tabletop di breve orizzonte; non include locomozione complessa.


4. Contributi principali

- Primo modello foundation aperto per umanoidi generalisti.
- Architettura dual-system (Vision-Language + Diffusion Transformer).
- Piramide dati con fonti umane, sintetiche e reali.
- Supporto multi-embodiment.
- Robustezza few-shot su robot reale.

5. Conclusioni

GR00T N1 dimostra che i foundation model possono essere applicati efficacemente alla robotica. Sviluppi futuri: locomozione, ambienti ampi, e migliore integrazione linguistica-spaziale.

6. Schema della struttura di GR00T N1



Lo schema mostra la pipeline principale: visione/linguaggio $\rightarrow$ codifica $\rightarrow$ generazione azioni.