

Riassunto Dettagliato e Aggiornato:
*Towards leveraging the role of machine learning
and artificial intelligence in precision agriculture
and smart farming*
Computers and Electronics in Agriculture 198
(2022) 107119

NECKER

Basato sul PDF originale + qualche precisazione

7 Dicembre 2025

Sommario

Il presente documento fornisce una disamina tecnica e approfondita dell'articolo "*Towards leveraging the role of machine learning and artificial intelligence in precision agriculture and smart farming*", pubblicato su *Computers and Electronics in Agriculture*. Viene esplorato l'impatto della digitalizzazione nel settore agricolo, analizzando le metodologie di Intelligenza Artificiale (AI) e Machine Learning (ML) applicate alle fasi di pre-raccolta, gestione delle colture, irrigazione e previsione della resa, nonché le sfide aperte e le prospettive future.

Indice

1	Introduzione: La Rivoluzione dell'Agricoltura 4.0	3
2	Tecnologie Abilitanti: AI e Machine Learning	3
2.1	Machine Learning Supervisionato	3
2.2	Machine Learning Non Supervisionato	8
2.2.1	K-means:	8
2.2.2	Esempio: Zonazione Agricola tramite K-means	8
2.2.3	Fuzzy C-means (FCM):	9
2.2.4	Esempio: Mappatura di Transizione del Suolo tramite FCM	10
2.2.5	Reti Neurali Artificiali (ANN - Unsupervised):	10
2.2.6	Esempio: Analisi Spettrale Iperspettrale tramite KSOM	11
2.3	Riduzione della Dimensionalità	12
2.3.1	PCA (Analisi delle Componenti Principali):	12
2.3.2	LDA (Analisi Discriminante Lineare):	13
2.4	Deep Learning (DL)	14

2.4.1	CNN (Convolutional Neural Networks):	14
2.4.2	RNN (Recurrent Neural Networks) e LSTM (Long Short-Term Memory):	15
3	Applicazioni nell'Automazione Agricola (Pre-Raccolta)	17
3.1	Analisi del Suolo e delle Sementi	17
3.2	Rilevamento e Classificazione delle Malattie	17
3.3	Fenotipizzazione delle Colture	17
3.4	Gestione di Fertilizzanti e Pesticidi	18
3.5	Rilevamento delle Erbe Infestanti (Weed Detection)	18
3.6	Irrigazione Intelligente	18
4	Sistemi, Piattaforme e Previsione della Resa	19
4.1	Previsione della Resa (Crop Yield Prediction)	19
4.2	Droni (UAV) e WSN	19
5	Sfide Aperte e Limitazioni	19
6	Prospettive Future	20

1 Introduzione: La Rivoluzione dell'Agricoltura 4.0

L'agricoltura rappresenta il 6,4% del PIL globale e costituisce la fonte primaria di sostentamento per milioni di persone. Tuttavia, la domanda alimentare globale è destinata a crescere del 70% entro il 2050. Questo scenario impone un cambio di paradigma verso pratiche sostenibili, dato che l'attuale produzione alimentare consuma risorse a ritmi insostenibili (il 70% dell'acqua dolce è destinata all'agricoltura).

L'articolo introduce i concetti di **Smart Farming (SF)** e **Agricoltura di Precisione (PA)** come risposte tecnologiche a queste sfide.

- **Smart Farming (SF):** L'applicazione di tecnologie IoT (Internet of Things) e AI nella gestione cyber-fisica delle aziende agricole.
- **Agricoltura di Precisione (PA):** La scienza volta a migliorare la resa delle colture e supportare le decisioni gestionali attraverso sensori e strumenti di analisi, ottimizzando l'uso di fertilizzanti e irrigazione.

L'obiettivo è trasformare l'agricoltura in un'industria data-driven ("Agricoltura 4.0"), capace di generare, trasferire ed elaborare dati per aumentare l'efficienza e ridurre l'impatto ambientale.


2 Tecnologie Abilitanti: AI e Machine Learning

Il documento categorizza le tecniche computazionali utilizzate in agricoltura in quattro macro-aree principali: apprendimento supervisionato, non supervisionato, riduzione della dimensionalità e deep learning.

2.1 Machine Learning Supervisionato

In questa categoria, l'algoritmo apprende una funzione che mappa un input a un output basandosi su coppie di input-output esempio fornite durante la fase di addestramento (per esempio migliaia di immagini con l'etichetta che indica cosa deve prevedere il modello da quell'immagine).

- **Support Vector Machine (SVM):**




Questo classificatore costruisce un iperpiano (o un insieme di iperpiani) in uno spazio dimensionale elevato, puntando a massimizzare il "margine", ovvero la distanza tra i punti dati più vicini delle diverse classi.

- **Meccanismo:** Utilizza il "kernel trick" per trasformare uno spazio di input a bassa dimensione in uno a dimensione superiore, rendendo separabili problemi che non lo sono linearmente. L'ottimizzazione viene spesso gestita tramite l'algoritmo SMO (Sequential Minimal Optimization).
- **Vantaggi e Limiti:** È particolarmente efficace in spazi ad alta dimensione, anche quando il numero di dimensioni supera quello dei campioni. Tuttavia, non è scalabile su dataset molto grandi e le prestazioni degradano in presenza di molto rumore o classi sovrapposte.

Esempio: Classificazione Mele tramite SVM

- * **Scenario:** Separare le mele in classi **Premium** e **Standard** utilizzando misure di *Diametro* e *Durezza*.
- * **Funzionamento:** L'SVM non si accontenta di una linea di separazione qualsiasi, ma trova quella che garantisce il massimo margine di tolleranza, definito dai *Vettori di Supporto* (le mele che si trovano proprio sul confine tra le classi). Se la separazione lineare fallisce (es. le mele Premium sono annidate al centro), l'algoritmo applica il **Kernel Trick** (es. Kernel RBF). Questo proietta le feature in uno spazio dimensionale superiore dove le classi diventano separabili linearmente.

• Alberi Decisionali (Decision Tree):




Un modello non parametrico che suddivide i dati ricorsivamente in nodi per massimizzare la discriminazione tra le classi.

- **Criteri di Split:** La suddivisione può basarsi su una singola caratteristica (*Univariate*) o su più caratteristiche (*Multivariate*). Per quantificare la qualità dello split vengono utilizzati l'Indice di Gini, il Guadagno di Informazione (Information Gain) e l'Entropia.
- **Caratteristiche:** Non richiede la normalizzazione o lo scaling dei dati e gestisce bene sia feature numeriche che categoriche senza hot-encoding.
- **Criticità:** Soffre di instabilità (piccole variazioni nei dati alterano drasticamente la struttura dell'albero) e tende all'overfitting. Inoltre, è inadeguato per prevedere valori continui in compiti di regressione complessa.

Esempio: Classificazione Mele tramite Albero Decisionali

- * **Scenario:** Classificare rapidamente le mele in **Premium** o **Scarto** per l'eliminazione dei frutti difettosi.
- * **Funzionamento:** L'algoritmo crea una serie di domande sequenziali. Al primo nodo, sceglie la feature che riduce maggiormente l'impurità (aumenta l'omogeneità): ad esempio, "La durezza è ≤ 6 ". Sul ramo risultante, si pone la domanda successiva più informativa, ad esempio: "Il diametro è ≤ 5 cm?".
- * **Output:** Il risultato è un percorso decisionale chiaro e interpretabile: **Se Durezza ≤ 6 E Diametro ≤ 5 , allora CLASSE = Scarto.**

- **k-Nearest Neighbors (k-NN):**




Definito come un metodo di apprendimento "pigro" (lazy learning) o basato sulle istanze (Instance-Based Learning - IBK), k-NN non costruisce un modello durante il training ma utilizza direttamente le istanze di addestramento per classificare i nuovi dati.

- **Funzionamento:** Crea un modello localmente ottimizzato per ogni istanza di test basandosi sulla vicinanza ai k vicini.
- **Vantaggi e Limiti:** È semplice da implementare per problemi multi-classe e permette l'aggiunta di nuovi dati senza riaddestramento. Tuttavia, è sensibile agli outlier, richiede feature omogenee e soffre della "maledizione della dimensionalità", diventando lento con dataset voluminosi.

Esempio: Classificazione Mele tramite k-NN

- * **Scenario:** Classificare una mela con caratteristiche ($x_1 = 7.2, x_2 = 6.5$) come 'Premium' o 'Standard'.
- * **Funzionamento:** L'algoritmo non ha un modello addestrato in anticipo. Al momento della classificazione, calcola la distanza euclidea della nuova mela da **tutte** le mele precedentemente etichettate. Vengono selezionati i k vicini più prossimi (es. $k = 5$). Se 4 dei 5 vicini sono etichettati come 'Premium', la nuova mela è classificata per maggioranza come **Premium**.

- **Random Forest:**




Un algoritmo di ensemble che aggrega molteplici classificatori ad albero decisionale per migliorare l'accuratezza complessiva e mitigare i difetti del singolo albero.

- **Meccanismo:** Ogni albero nell'ensemble determina una classe per il campione e l'etichetta finale è decisa tramite una votazione di maggioranza.
- **Prestazioni:** È robusto agli outlier e al rumore, riduce il rischio di overfitting e gestisce bene dati non lineari. Di contro, l'addestramento è lento, può presentare bias con variabili categoriche e non è ideale per metodi lineari con molte feature sparse.

Esempio: Classificazione Mele tramite Random Forest

- * **Scenario:** Classificazione ad alta precisione della qualità della mela utilizzando molteplici feature (Diametro, Durezza, Peso, Acidità).
- * **Funzionamento:** Viene creata una "foresta" di Alberi Decisionali. Ogni albero è addestrato su un sottoinsieme campionamento casuale (bootstrap) dei dati e, crucialmente, su un sottoinsieme casuale delle feature (garantendo la decorrelazione tra gli alberi). Per la classificazione finale di una nuova mela, ogni albero esprime un voto ('Premium' o 'Standard'). Il voto di maggioranza della foresta è la previsione finale.

- **Naïve Bayes:**



Un modello generativo probabilistico basato sul teorema di Bayes, noto per la sua velocità e capacità di gestire dati ad alta dimensione.

- **Assunzioni:** Si fonda sull'assunzione (spesso irrealistica) che tutte le feature siano indipendenti tra loro.
- **Problema "Zero Frequency":** Se nel dataset di test appare una variabile categorica non presente nel training set, il modello le assegna una probabilità zero, rendendo impossibile la previsione (fenomeno noto come "Zero Frequency"). È comunque eccellente per valori categorici e problemi di previsione multi-classe.

Esempio: Rilevamento Malattie Mele tramite Naïve Bayes

- * **Scenario:** Prevedere la probabilità che una mela sia ****Malata**** date feature binarie (es. Presenza di Macchie X_1 , Colore Anomalo X_2).
- * **Funzionamento:** L'algoritmo calcola la probabilità a posteriori che la mela sia malata ($\text{Classe } Y = 1$) moltiplicando la probabilità a priori di Y per le probabilità condizionali di ogni singola feature, assumendo che $P(X_1|Y) \times P(X_2|Y)$ sia valido.
- * **Formula Concettuale:** $P(\text{Malata}|X_1, X_2) \propto P(\text{Malata}) \times P(X_1|\text{Malata}) \times P(X_2|\text{Malata})$.

2.2 Machine Learning Non Supervisionato

Il Machine Learning Non Supervisionato (Unsupervised Learning) si applica quando i dati di input non possiedono etichette di classe predefinite. Il suo obiettivo primario è quello di esplorare la struttura intrinseca del dataset, identificando **pattern nascosti**, **raggruppamenti naturali** (clustering) o **strutture latenti** (riduzione della dimensionalità) per scopi diagnostici ed esplorativi nell'agricoltura di precisione (in questo caso non abbiamo più etichette che ci dicono per esempio se una mela è premium o non lo è).

2.2.1 K-means:


Il K-means opera in un ciclo iterativo che mira a minimizzare la **Sum of Squared Errors (SSE)**, ovvero la distanza quadratica totale tra i punti e i centroidi dei rispettivi cluster. Il processo si articola in tre fasi principali:

1. **Inizializzazione:** Si scelgono casualmente k punti come centroidi iniziali (μ_i).
2. **Assegnazione (E-Step):** Ogni punto dati viene assegnato al cluster il cui centroide è **geometricamente più vicino** (tipicamente misurato con distanza euclidea).
3. **Aggiornamento (M-Step):** I centroidi vengono ricalcolati come la **media aritmetica** di tutti i punti assegnati al cluster.

Il ciclo si ripete (passi 2 e 3) finché i centroidi non si stabilizzano o non viene raggiunta la convergenza.

Limitazioni

È efficiente, ma fortemente sensibile alla scelta iniziale di k e dei centroidi. Inoltre, la presenza di **outlier** può distorcere in modo significativo i centroidi, portando a raggruppamenti sub-ottimali.



2.2.2 Esempio: Zonazione Agricola tramite K-means

- **Scenario:** Suddividere un grande campo agricolo in regioni omogenee (zone di gestione) in base alle proprietà del suolo o alla vigoria vegetativa.

- **Meccanismo:** L'algoritmo richiede che l'utente specifichi in anticipo il numero di cluster k (ad esempio, 3 zone: Alta, Media, Bassa Vigoria). Inizialmente, vengono scelti k centroidi casuali. Ogni punto dati (es. misurazione del suolo) viene assegnato al centroide più vicino in base alla distanza euclidea. I centroidi vengono ricalcolati come media di tutti i punti assegnati, e il processo si ripete fino a quando i centroidi non convergono (non cambiano più posizione).

2.2.3 Fuzzy C-means (FCM):

L'obiettivo di FCM è minimizzare una funzione di costo (detta funzione obiettivo) che è una variazione della SSE, ponderata dai gradi di appartenenza u_{ij} . Il processo è iterativo:

1. **Inizializzazione:** Si stabilisce il numero di cluster (C) e l'esponente di sfocatura m (tipicamente $m = 2$). Viene inizializzata casualmente la **Matrice di Appartenenza** U , dove l'elemento u_{ij} rappresenta il grado di appartenenza del punto i al cluster j . La somma dei gradi di appartenenza di un punto deve essere pari a 1 ($\sum_{j=1}^C u_{ij} = 1$).
2. **Aggiornamento dei Centri:** I centroidi μ_j vengono calcolati come una media ponderata dei punti dati. Il peso di ogni punto è dato dal suo grado di appartenenza elevato all'esponente di sfocatura m :

$$\mu_j = \frac{\sum_{i=1}^N (u_{ij})^m \cdot x_i}{\sum_{i=1}^N (u_{ij})^m}$$


3. **Aggiornamento della Matrice di Appartenenza (U):** La matrice U viene aggiornata in base alla distanza di ogni punto dai nuovi centroidi, rafforzando l'appartenenza ai cluster più vicini e diminuendola per quelli più lontani:

$$u_{ij} = \frac{1}{\sum_{k=1}^C \left(\frac{\|x_i - \mu_j\|}{\|x_i - \mu_k\|} \right)^{\frac{2}{m-1}}}$$

Il ciclo si ripete fino al raggiungimento della convergenza o quando la variazione massima dei gradi di appartenenza scende sotto una soglia minima.

Vantaggio Chiave

La natura "sfocata" di FCM è fondamentale nell'agricoltura di precisione, specialmente quando si analizzano dati con **confini ambigui**, come la transizione tra due tipi di suolo o la variazione graduale dello stress idrico in un campo. L'FCM gestisce meglio i dati che si sovrappongono e offre una visione più granulare e robusta delle zone di transizione rispetto al clustering rigido.



2.2.4 Esempio: Mappatura di Transizione del Suolo tramite FCM

- **Scenario:** Analizzare i dati di umidità del suolo per identificare regioni dove la transizione tra "secco" e "umido" non è netta.
- **Meccanismo:** A differenza del K-means, un punto dati non appartiene rigidamente a un solo cluster, ma ha un **grado di appartenenza** a tutti i C cluster, quantificato da una matrice di appartenenza. Se un'area ha un'umidità intermedia, il punto dati potrebbe avere un'appartenenza del 60% al cluster 'Umido' e del 40% al cluster 'Intermedio'.

2.2.5 Reti Neurali Artificiali (ANN - Unsupervised):

Le ANN non supervisionate sono una classe di modelli, distinti dalle reti supervisionate (come le CNN), che non richiedono etichette di training. Sono primariamente utilizzate per l'apprendimento delle feature, tra queste le KSOM (o Self-Organizing Maps, SOM) sono un tipo di rete neurale che implementa l'apprendimento competitivo non supervisionato per produrre una rappresentazione a bassa dimensionalità (solitamente 2D) dei vettori di input, mantenendo al contempo le relazioni topologiche e di vicinanza dei dati originali.


1. **Struttura:** La KSOM è composta da un **layer di input** e da un **layer di mappa** (tipicamente una griglia 2D di neuroni). Ogni neurone sulla mappa è connesso a tutti i neuroni del layer di input tramite un vettore di pesi.
2. **Meccanismo Competitivo:** Dato un vettore di input x (es. il profilo spettrale di un pixel), l'algoritmo calcola la distanza tra x e il vettore di pesi w_j di ogni neurone j sulla mappa. Il neurone con il peso più vicino all'input viene dichiarato **Best Matching Unit (BMU)**.

$$BMU = \arg \min_j \|x - w_j\|$$

3. **Aggiornamento Topologico:** A differenza del K-means, non viene aggiornato solo il BMU, ma anche tutti i neuroni che si trovano nel suo **vicinato topologico** sulla griglia 2D. La quantità di aggiornamento è inversamente proporzionale alla distanza dal BMU sulla mappa (più è lontano, meno viene aggiornato) e diminuisce con l'avanzare del tempo (il raggio di vicinato si restringe gradualmente). Questo assicura che i dati simili siano mappati su neuroni vicini, preservando la struttura.

Vantaggio Chiave in Agricoltura

La KSOM è cruciale per l'analisi di dati agricoli estremamente complessi e ad alta dimensione, come le immagini **iperspettrali** (con centinaia di bande). Permette di visualizzare e clusterizzare profili spettrali simili (che potrebbero indicare lo stesso livello di stress idrico o la stessa malattia) su una semplice mappa 2D, permettendo agli agronomi di identificare pattern latenti e raggruppamenti di stress senza dover etichettare i dati in anticipo.



2.2.6 Esempio: Analisi Spettrale Iperspettrale tramite KSOM

- **Scenario:** Analizzare immagini iperspettrali ad altissima dimensionalità (centinaia di bande spettrali per pixel) per identificare tipi di vegetazione o stress idrico senza etichette iniziali.
- **Meccanismo (KSOM):** La KSOM è un tipo di rete neurale che crea una mappa a bassa dimensione (spesso 2D) che conserva le relazioni topologiche dei dati di input ad alta dimensione. I nodi vicini sulla mappa 2D rappresentano vettori di input simili. Nel contesto agricolo, se due pixel hanno profili spettrali simili (es. entrambi rappresentano una coltura sana), verranno mappati su neuroni vicini nella mappa KSOM, creando cluster visivi.

2.3 Riduzione della Dimensionalità


La Riduzione della Dimensionalità è una fase di pre-elaborazione essenziale nel Machine Learning, in particolare per i dati agricoli (come le misurazioni multispettrali o iperspettrali) caratterizzati da un elevato numero di variabili ($\mathbf{X}$). L'obiettivo è trasformare il set di dati da uno spazio ad alta dimensione in uno a bassa dimensione, **preservando la massima informazione possibile** o massimizzando la **separazione tra le classi**. Questo processo riduce la complessità computazionale e mitiga l'effetto della "maledizione della dimensionalità" (fenomeno per cui i dati diventano troppo dispersi in spazi molto grandi).

2.3.1 PCA (Analisi delle Componenti Principali):

La PCA è una tecnica di **riduzione della dimensionalità non supervisionata** che trova i sottospazi lineari che massimizzano la varianza dei dati proiettati.

Meccanismo e Applicazione (PCA)

- **Obiettivo:** Identificare un nuovo set di variabili ortogonali, chiamate **Componenti Principali (PC)**, che sono combinazioni lineari delle variabili originali. La prima PC cattura la massima varianza possibile nei dati, la seconda PC cattura la massima varianza residua e così via.
- **Funzionamento:** L'algoritmo calcola gli autovettori e gli autovalori della matrice di covarianza dei dati. Le PC sono gli autovettori, ordinati in base alla magnitudine dei loro autovalori (che rappresentano la varianza spiegata). Si selezionano solo le prime k PC che spiegano una percentuale significativa della varianza totale (es. 95%).
- **Vantaggio Agricolo:** Viene utilizzata per la **compressione** di immagini multispettrali o iperspettrali. Ad esempio, da 100 bande spettrali (feature) si possono selezionare 5 o 10 Componenti Principali che contengono quasi tutte le informazioni rilevanti sulla salute delle piante, riducendo drasticamente il tempo di addestramento per i successivi classificatori (come SVM o CNN).



2.3.2 LDA (Analisi Discriminante Lineare):


LDA è una tecnica di **riduzione della dimensionalità supervisionata** specificamente progettata per i problemi di classificazione.

Meccanismo e Applicazione (LDA)

- **Obiettivo:** Proiettare i dati in uno spazio a dimensione inferiore che **massimizzi la separazione tra le classi** (varianza inter-classe) e, contemporaneamente, **minimizzi la varianza all'interno di ogni classe** (varianza intra-classe).
- **Funzionamento:** A differenza della PCA (che ignora le etichette), LDA utilizza le etichette Y per trovare la migliore direzione proiettiva. L'algoritmo calcola una misura di separabilità e cerca le proiezioni che massimizzano il rapporto tra la varianza inter-classe e la varianza intra-classe.
- **Vantaggio Agricolo:** Se l'obiettivo è distinguere tra due classi (es. "Pianta Sana" vs. "Pianta Malata") utilizzando dati con molte feature (es. 20 indici di vegetazione), LDA garantisce che le feature proiettate siano le più efficaci per la classificazione. LDA è spesso usato come pre-processore prima dell'applicazione di classificatori semplici.

Differenza Fondamentale: Obiettivo

Mentre la **PCA** è un metodo non supervisionato che mira a **conservare la massima informazione possibile** (massimizzazione della varianza totale), la **LDA** è un metodo supervisionato che mira a **massimizzare la discriminazione di classe** (ottimizzazione della separazione tra le classi). Per un problema di classificazione, se le etichette sono disponibili e affidabili, LDA è generalmente più potente.



2.4 Deep Learning (DL)


Il Deep Learning (DL) rappresenta l'apice evolutivo delle Reti Neurali Artificiali (ANN) e si distingue per l'utilizzo di architetture con **molteplici strati nascosti** ("profondi"). La sua caratteristica fondamentale è l'eliminazione della necessità di **feature engineering manuale**: il modello è in grado di apprendere e estrarre automaticamente la gerarchia delle feature rilevanti direttamente dai dati grezzi (a differenza del **ML non supervisionato**, qua abbiamo le etichette ma il modello deve estrarre le feature).

2.4.1 CNN (Convolutional Neural Networks):

Le CNN sono architetture di rete neurale feed-forward altamente specializzate per l'analisi e l'elaborazione di dati strutturati a griglia, come immagini e dati spettrali. Sono la tecnologia dominante per la visione artificiale in agricoltura.

Meccanismo e Applicazione (CNN)

- **Strato di Convoluzione:** La funzione centrale è il **filtro convoluzionale** (kernel) che scorre sull'immagine di input (o su mappe di attivazione precedenti), eseguendo la moltiplicazione elemento per elemento per estrarre feature locali (bordi, angoli, texture). Ogni strato successivo apprende feature di complessità crescente.
- **Strato di Pooling:** Riduce la dimensionalità spaziale (compressione), diminuendo il numero di parametri e rendendo le feature estratte meno sensibili a piccole traslazioni nell'input.
- **Funzione di Attivazione ReLU:** (Rectified Linear Unit) Introduce la non linearità, permettendo alla rete di apprendere relazioni complesse che altrimenti sarebbero impossibili con trasformazioni lineari.
- **Applicazione Agricola:** Sono impiegate per il **riconoscimento delle malattie** (es. Classificazione delle foglie nel dataset PlantVillage), il **rilevamento di frutti** (per la raccolta automatizzata), e l'identificazione di **infestanti** (weed detection) tramite droni. Architetture pre-addestrate come AlexNet, VGG e ResNet sono spesso riutilizzate tramite **Transfer Learning**.



2.4.2 RNN (Recurrent Neural Networks) e LSTM (Long Short-Term Memory):

Le RNN sono progettate specificamente per elaborare **dati sequenziali** o **serie temporali** (tempo, sequenza di pixel, parole). A differenza delle reti feed-forward, mantengono una "memoria" degli input passati.

Meccanismo e Applicazione (RNN/LSTM)

- **Il Limite delle RNN Classiche:** Le RNN standard soffrono del problema del **vanishing gradient** (gradiente evanescente), che impedisce loro di apprendere dipendenze a lungo termine nei dati (es. la correlazione tra piogge avvenute 6 mesi fa e la resa attuale).
- **LSTM (Long Short-Term Memory):** Questa è la variante più usata e risolve il problema tramite l'introduzione di **celle di memoria** e **gate** (Input, Forget, Output). Questi gate controllano in modo selettivo quali informazioni devono essere mantenute nella memoria di lungo termine, quali dimenticate e quali esposte.
- **Applicazione Agricola:** Le LSTM sono cruciali per la **previsione della resa** delle colture. Possono modellare efficacemente la dipendenza temporale tra variabili ambientali (dati climatici storici, temperature, precipitazioni, indici di vegetazione misurati nel tempo) e la resa finale della coltura.




Tabella Riassuntiva:

Metodologia	Modalità	Fonte delle Feature (X)	Necessità Etichetta (Y)
ML Tradizionale	Supervisionato (e.g., SVM)	Fornite dall'uomo (Feature Engineering Manuale)	SÌ
	Non Supervisionato (e.g., K-means)	Fornite dall'uomo (Feature Engineering Manuale)	NO
Deep Learning	Supervisionato (e.g., CNN)	Apprese Automaticamente (dal dato grezzo)	SÌ
	Non Supervisionato (e.g., Autoencoder)	Apprese Automaticamente (dal dato grezzo)	NO

3 Applicazioni nell'Automazione Agricola (Pre-Raccolta)

L'articolo analizza dettagliatamente come queste tecnologie vengono applicate nelle fasi precedenti al raccolto.

3.1 Analisi del Suolo e delle Sementi

La classificazione delle proprietà del suolo aiuta a ridurre i costi dei fertilizzanti. Modelli come ELM (Extreme Learning Machine) e SVM sono usati per prevedere pH, carbonio organico e umidità. Per le sementi, la visione artificiale e le CNN (es. VGG19, GoogLeNet) vengono impiegate per:

- Classificare semi di alta qualità vs bassa qualità (es. nel peperone).
- Stimare il numero di semi per baccello (es. soia).
- Identificare difetti morfologici.

3.2 Rilevamento e Classificazione delle Malattie

Questa è una delle aree più critiche. L'identificazione precoce previene perdite massicce.

- **Metodi Convenzionali:** Utilizzano feature estratte manualmente (colore, texture) e classificatori come SVM o k-NN. Esempi includono il rilevamento di malattie fungine su uva, agrumi e soia con accuratezze che variano dall'88% al 97%.
- **Deep Learning:** Le CNN (AlexNet, ResNet, VGG) hanno mostrato prestazioni superiori, raggiungendo accuratezze oltre il 99% (es. dataset PlantVillage). Il DL gestisce meglio la variabilità e non richiede feature engineering manuale, rendendolo adatto per app mobili diagnostiche (es. Plantix).

3.3 Fenotipizzazione delle Colture

La fenotipizzazione automatizzata misura le caratteristiche fisiche e biochimiche delle piante (crescita, tolleranza allo stress). Sistemi basati su sensori iperspettrali, LiDAR e veicoli autonomi (robot terrestri o droni) permettono di superare il "collo di bottiglia" delle misurazioni manuali, accelerando i programmi di selezione genetica.

3.4 Gestione di Fertilizzanti e Pesticidi

L'uso eccessivo di agrochimici danneggia l'ecosistema e la salute umana.

- **Rilevamento Parassiti:** Modelli di visione artificiale e acustici identificano specifici insetti nocivi, permettendo l'applicazione mirata di pesticidi (es. tecnologia "See & Spray" che riduce l'uso di chimici dell'80%).
- **Ottimizzazione:** Algoritmi predittivi suggeriscono le quantità esatte di nutrienti necessarie in base alle condizioni del suolo in tempo reale.

3.5 Rilevamento delle Erbe Infestanti (Weed Detection)

Le infestanti competono per le risorse. L'articolo evidenzia l'uso di droni e robot terrestri dotati di telecamere multispettrali e algoritmi (es. Random Forest, CNN) per distinguere le colture dalle infestanti, permettendo trattamenti localizzati (spot spraying) invece che a tappeto.

3.6 Irrigazione Intelligente

L'ottimizzazione idrica è vitale. Sistemi IoT con sensori di umidità del suolo e stazioni meteo, combinati con algoritmi come Naïve Bayes o alberi decisionali, controllano automaticamente le valvole di irrigazione. Piattaforme commerciali (es. ConsertWater) usano dati satellitari per prevedere il fabbisogno idrico, risparmiando fino al 30% di acqua.

4 Sistemi, Piattaforme e Previsione della Resa

4.1 Previsione della Resa (Crop Yield Prediction)

Prevedere quanto produrrà un campo è essenziale per la sicurezza alimentare e l'economia.

- È un problema complesso influenzato da genotipo, ambiente e gestione.
- Il Deep Learning (in particolare LSTM e CNN-RNN ibride) supera i metodi tradizionali perché riesce a modellare le relazioni non lineari tra dati storici, meteo e immagini satellitari.
- Esempi citati includono la previsione della resa della soia in Brasile e del riso in Corea, integrando dati spaziali e temporali.

4.2 Droni (UAV) e WSN

I droni non sono solo strumenti di monitoraggio ma piattaforme attive per la mappatura del vigore delle piante (NDVI) e l'irrigazione. Le reti di sensori wireless (WSN) formano l'infrastruttura di base per la raccolta dati continua (temperatura, umidità, pH), trasmettendo via protocolli come LoRaWAN o ZigBee.

5 Sfide Aperte e Limitazioni

Nonostante i progressi, il documento identifica diverse barriere significative:

1. **Scarsità e Qualità dei Dati:** Mancanza di grandi dataset etichettati pubblici (oltre a PlantVillage). Molti dataset sono piccoli o proprietari.
2. **Condizioni Reali vs Laboratorio:** La maggior parte dei modelli è addestrata su immagini con sfondi uniformi e illuminazione controllata, fallendo in campo aperto dove ci sono ombre, sovrapposizioni e sfondi complessi.
3. **Standardizzazione:** Manca interoperabilità tra dispositivi e formati dati diversi.
4. **Scalabilità:** La gestione di "Big Data" eterogenei richiede algoritmi scalabili e hardware potente (GPU/TPU).
5. **Droni:** Limitazioni della batteria (autonomia < 1 ora), costi elevati dei sensori iperspettrali e normative di volo restrittive.

6 Prospettive Future

L'articolo conclude suggerendo direzioni di ricerca prioritarie:

- **Identificazione dello Stadio della Malattia:** Non basta rilevare la malattia, bisogna capire in che stadio si trova per decidere il trattamento.
- **Quantificazione del Danno:** Sviluppare sistemi che calcolino la percentuale di infezione o danno per dosare i chimici.
- **Applicazioni Mobile Offline:** Sviluppare app leggere ed efficienti utilizzabili dagli agricoltori direttamente sul campo, anche senza connessione internet.
- **Transfer Learning:** Utilizzare modelli pre-addestrati per mitigare la carenza di dati specifici per certe colture.

Riferimenti bibliografici

- [1] Tawseef Ayoub Shaikh, Tabasum Rasool, Faisal Rasheed Lone (2022).
Towards leveraging the role of machine learning and artificial intelligence in precision agriculture and smart farming.
Computers and Electronics in Agriculture, 198, 107119.
<https://doi.org/10.1016/j.compag.2022.107119>